

本科毕业论文规范格式(理工科)

学号 2206040130

年级 2022级

本科毕业论文

基于神经网络的端侧语义通信系统设计与实现

专 业 智能科学与技术

姓 名 王玺硕

指导教师 吴铭

评阅人

2026年5月

中国 南京

**BACHELOR'S DEGREE THESIS
OF HOHAI UNIVERSITY**

**Design and Implementation of an Edge
Semantic Communication System Based on
Neural Networks**

College : Artificial Intelligence and Automation

Subject : Intelligence Science and Technology

Name : Xishuo Wang

Directed by : Ming Wu

NANJING CHINA

郑 重 声 明

本人呈交的毕业论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本设计（论文）的研究成果不包含他人享有著作权的内容。对本设计（论文）所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本设计（论文）的知识产权归属于培养单位。

本人签名：_____

日期：_____

摘 要

随着边缘智能设备和无线多媒体业务的发展，无线通信系统传输的内容不再局限于传统比特流，而是逐渐扩展到图像、视频以及面向识别、监测和重建的视觉信息。传统通信系统通常要求接收端尽可能准确地恢复发送比特，这种机制在文件传输、控制指令传输等场景中较为可靠。然而，在图像语义传输任务中，接收端更关注图像主体、结构轮廓和关键视觉内容是否能够有效保留，而不一定要求每个像素都与原始图像完全一致。基于这一需求，本文面向边缘设备和真实无线链路，设计并实现了一套图像语义通信系统，重点研究语义压缩表示、神经网络辅助物理层处理、端侧部署和真实空口验证之间的协同机制。

在系统设计方面，发送端利用变分自编码器将输入图像压缩为低维潜变量，并结合Top-K选择、量化和低密度奇偶校验码，将语义特征进一步组织为适合物理层传输的比特序列。物理层部分在统一链路框架下引入基于神经网络的调制映射与软信息恢复模块，并设计可训练星座图，用于分析神经网络对传统调制映射和接收判决过程的增强作用。空口实验部分基于USRP X310软件无线电平台完成实际无线传输，并结合导频同步、信道估计和接收端前端处理，提高真实链路下的传输稳定性。端侧部署部分面向Jetson Orin平台，对语义编解码和链路处理流程进行推理加速与运行优化，以提升系统在边缘端运行时的实时性。

实验结果表明，本文系统能够完成从图像语义提取、无线传输到接收端图像重构的闭环验证。在仿真信道下，神经网络辅助物理层处理和可训练星座图能够改善调制映射与接收判决之间的匹配关系；在真实空口实验中，相比标准16-QAM，可训练星座图在不同功率放大器增益下呈现出更清晰的接收聚类轮廓和更稳定的类间区分度。端侧时延测试结果表明，经过推理后端和运行流程优化后，系统端到端时延由3464.9 ms降至639.8 ms，降低81.54%。上述结果说明，神经网络方法在端侧语义表示、物理层映射和边缘推理优化中具有一定的实际应用价值，也为图像语义通信系统的工程实现提供了一种可行方案。

关键词： 语义通信；端侧部署；神经网络

ABSTRACT

With the development of edge intelligent devices and wireless multimedia services, the content transmitted by wireless communication systems is no longer limited to conventional bit streams, but has gradually expanded to images, videos, and visual information for recognition, monitoring, and reconstruction. Traditional communication systems usually require the receiver to recover the transmitted bits as accurately as possible. This mechanism is reliable in scenarios such as file transmission and control instruction transmission. However, in image semantic transmission tasks, the receiver is more concerned with whether the main object, structural outline, and key visual content can be effectively preserved, rather than requiring every pixel to be exactly the same as the original image. Based on this demand, this thesis designs and implements an image semantic communication system for edge devices and real wireless links, focusing on the coordination among semantic compression representation, neural-network-assisted physical-layer processing, edge deployment, and real over-the-air validation.

In terms of system design, the transmitter uses a variational autoencoder to compress the input image into low-dimensional latent variables. Combined with Top-K selection, quantization, and low-density parity-check coding, the semantic features are further organized into bit sequences suitable for physical-layer transmission. At the physical layer, neural-network-based modulation mapping and soft-information recovery modules are introduced under a unified link framework, and a trainable constellation is designed to analyze the enhancement effect of neural networks on conventional modulation mapping and receiver decision making. For over-the-air experiments, a real wireless transmission link is built on the USRP X310 software radio platform, where pilot synchronization, channel estimation, and receiver front-end processing are used to improve transmission stability in practical links. For edge deployment, the system is implemented on the Jetson Orin platform, and inference acceleration together with runtime optimization is applied to the semantic encoding, decoding, and link-processing workflow to improve real-time performance at the edge.

Experimental results show that the proposed system can complete the closed-loop validation from image semantic extraction and wireless transmission to image reconstruction at the receiver. In simulated channels, the neural-network-assisted physical-layer processing and the trainable constellation improve the matching between modulation mapping and

receiver decisions. In real over-the-air experiments, compared with standard 16-QAM, the trainable constellation presents clearer received clusters and more stable inter-class separability under different power amplifier gains. Edge latency tests show that, after inference backend and runtime workflow optimization, the end-to-end latency is reduced from 3464.9 ms to 639.8 ms, achieving an 81.54% reduction. These results indicate that neural-network-based methods have certain practical value in edge semantic representation, physical-layer mapping, and edge inference optimization, and provide a feasible solution for the engineering implementation of image semantic communication systems.

Keywords: semantic communication; edge deployment; neural networks

目 录

摘 要	I
ABSTRACT	II
目 录	IV
第1章 绪论	1
1.1 研究背景与意义	1
1.1.1 语义通信与图像语义传输研究	2
1.1.2 神经网络物理层研究	2
1.1.3 端侧AI与真实链路验证研究	3
1.2 本文主要研究内容	3
1.3 本文结构安排	4
第2章 相关技术与理论分析	5
2.1 引言	5
2.2 语义通信与图像潜变量表示	5
2.2.1 从比特可靠性到语义有效性	6
2.2.2 变分自编码器与潜变量压缩	6
2.2.3 重要性选择与量化误差	7
2.3 可靠无线物理层理论基础	9
2.3.1 LDPC编码与软判决译码	9
2.3.2 QAM星座与软解调模型	10
2.3.3 OFDM、导频与信道估计	10
2.4 神经网络物理层替代理论	11
2.4.1 通信自编码器与可训练收发机	11
2.4.2 神经调制与神经软解调	12
2.4.3 可训练星座图的参数化解释作用	12
2.5 边缘计算与端侧AI加速理论	12
2.5.1 计算图编译与算子融合理论	13
2.5.2 精度降维与显存带宽管理	13
2.5.3 推理引擎执行映射与零拷贝机制	14

2.6 软件无线电与空口信道特性	14
2.6.1 软件无线电与USRP工作原理	14
2.6.2 理想仿真信道与真实空口的差异	15
2.7 本章小结	15
第3章 端侧神经语义通信系统设计与实现	17
3.1 引言	17
3.2 系统总体架构设计	17
3.2.1 系统功能划分	17
3.2.2 三类链路关系	19
3.3 发送端语义编码与帧组织设计	19
3.3.1 图像语义潜变量提取	19
3.3.2 Top-K选择与分位数量化	20
3.3.3 信道编码与复数符号映射	20
3.4 接收端解调译码与语义重建设计	21
3.4.1 帧解析与软信息恢复	21
3.4.2 语义比特恢复与反量化	22
3.4.3 VAE语义重建	22
3.5 基于神经网络的调制与软解调模块设计	23
3.5.1 神经调制器结构	23
3.5.2 神经软解调器结构	24
3.5.3 传统模块与神经模块的衔接	25
3.6 可训练星座图与OFDM链路适配设计	25
3.6.1 可训练16QAM星座参数化	25
3.6.2 OFDM链路损伤建模	26
3.7 USRP接收前端设计	27
3.7.1 导频同步与信道估计	27
3.7.2 残差补偿前端	27
3.8 边缘端实时部署与优化设计	28
3.8.1 TensorRT编解码后端推理优化	28
3.8.2 物理层批处理优化	29
3.8.3 工程鲁棒性设计	29
3.9 本章小结	30

第4章 实验与分析	31
4.1 引言	31
4.2 实验平台与评价指标	31
4.2.1 硬件实验平台	31
4.2.2 软件环境与实验工具	32
4.2.3 实验评价指标	33
4.3 仿真环境下的物理层消融实验	34
4.3.1 神经物理层替换方案的分阶段对比实验	34
4.3.2 可训练星座图仿真对比实验	36
4.4 真实空口下的物理层系统验证实验	37
4.4.1 空口实验设置	37
4.4.2 真实空口下替换物理层的接收星座观测	38
4.5 边缘端性能与时延实验分析	40
4.5.1 边缘端推理时延统计方法	40
4.5.2 各模块时延优化结果	40
4.6 端到端图像语义通信重构质量分析	42
4.7 本章小结	44
第5章 总结与展望	45
5.1 全文工作总结	45
5.2 主要工作特点	46
5.3 不足与改进方向	47
5.4 未来研究展望	47
参考文献	49

第1章 绪论

1.1 研究背景与意义

无线通信长期以可靠传输为核心目标。Shannon^[1]建立的信息论框架给出了信道容量、编码可靠性和误码概率等基础概念，Shannon与Weaver^[2]进一步从通信层级角度讨论了信息传递问题，后续信息论教材也将这一体系整理为现代通信系统的基础分析工具^[3]。在传统语音、文本和文件传输中，这种范式非常有效，因为接收端通常需要恢复与发送端一致的比特序列。然而，随着通信对象逐渐扩展到图像、视频、智能感知和机器协同任务，仅以比特正确为目标已经显得有些不够。接收端真正需要的，往往不是每一个像素或比特都完全一致，而是能够恢复图像主体、结构轮廓以及后续识别、观察和重建所需的关键视觉信息。

语义通信（Semantic Communication）正是在这一背景下受到关注。它试图回答一个更贴近智能应用的问题：通信系统能否优先传输对图像理解和重建更有价值的信息，而不是完整复刻原始数据？在本文中，语义通信主要指面向图像内容理解与重建的通信方式，系统更关注主体结构、轮廓和场景关系能否被接收端恢复，而不是逐比特、逐像素完全一致。张平等^[4]从语义通信的基本原理出发，指出未来通信需要在语义度量、语义编码和资源效率之间建立新的协同关系。近年来，深度联合信源信道编码、语义特征选择和生成式语义重建等研究不断推进，说明神经网络能够在图像传输中学习更紧凑的表示方式，并在低信噪比（Signal-to-Noise Ratio, SNR）或带宽受限条件下保持较平滑的质量退化^[5-9]。SNR用于衡量有用信号功率与噪声功率之间的相对大小，是评价无线链路工作条件的重要指标。与以比特完全一致为中心的传统链路相比，语义通信把评价重点前移到内容表达和任务可用性上，这为图像无线传输提供了新的系统设计思路。

与此同时，人工智能（Artificial Intelligence, AI）正在进入无线物理层。AI在本文中主要指由神经网络驱动的可训练模型，用于学习传统解析模型难以完全刻画的非线性映射、软信息恢复和端侧推理过程。传统物理层依赖清晰的数学模型，包括调制星座、软判决解调、信道估计、均衡和信道译码等模块。这些方法成熟、稳定、可解释，但在真实无线链路中会受到频偏、相位旋转、硬件非理想和信道失配等因素影响。神经网络物理层的研究尝试用可训练模型替代或增强部分传统模块，例如学习调制映射、训练神经接收机和优化星座几何结构^[10-14]。它的吸引力不在于把传统理论全部推翻，而在于让系统在复杂条件下多一种自适应能力。

端侧部署进一步提高了问题难度。语义通信和神经物理层都依赖神经网络推理，

若只在高性能服务器上验证,并不能说明系统适合真实边缘场景。端侧设备更关注计算资源、显存占用、连续帧延迟和链路稳定性^[15-17]。刘旺等^[18]在边缘算力网络语义通信综述中也强调,计算资源约束已经成为语义通信从理论方案走向实际应用时必须面对的问题。

基于上述背景,本文围绕语义压缩、神经网络物理层替代、可训练星座图、真实复基带接收前端以及边缘图形处理器(Graphics Processing Unit, GPU)优化展开研究。GPU在本文中主要承担神经网络推理与并行基带处理任务,其并行计算能力直接影响通信链路的实时运行效果。与仅关注单个模块离线性能的研究不同,本文更强调各环节之间的系统协同,目标是形成一条可运行、可评估并具备部署优化潜力的图像语义通信链路。

1.1.1 语义通信与图像语义传输研究

语义通信最初关注意义怎样表达、通信目标如何度量。进入第六代移动通信(Sixth-Generation Mobile Communication, 6G)研究阶段后,相关讨论逐渐从链路吞吐量扩展到任务完成度、语义一致性和资源利用效率^[19-22]。6G面向智能连接、泛在感知和空天地一体化场景,语义通信则为人工智能和无线网络之间搭建了新的接口。中文研究中,张平等^[23]从6G移动通信演进角度讨论智能化、泛在化和资源高效利用趋势;秦志金等^[24]围绕多模态数据梳理文本、图像、音频和视频语义通信脉络。近几年,生成式人工智能和大模型继续推动这一方向,生成先验、扩散模型和语义提示开始被用于图像或视频内容恢复^[25-27]。

图像语义通信是当前较活跃的应用方向。深度联合信源信道编码(Deep Joint Source-Channel Coding, DeepJSCC)类方法将源压缩和信道保护联合优化,使接收端图像质量随信道恶化逐渐下降,避免传统分离式编码中的突变失效现象^[5,6]。DeepJSCC强调压缩表示和抗信道噪声同时学习,因此很适合解释图像语义通信中质量平滑退化的现象。罗鹏等^[28]围绕全局与局部上下文特征融合设计语义通信系统,说明图像内容的结构性表达对于语义恢复具有直接价值。2025年以来,面向图像传输的语义通信研究进一步强调信道自适应、向量量化表示、生成式恢复和边缘侧协同^[8,9,29,30]。不过,这类研究仍有一个现实问题:许多工作以仿真信道为主,离端侧实时系统和真实无线前端还有一段距离。

1.1.2 神经网络物理层研究

神经网络物理层的研究大致经历了三个阶段。早期工作将通信链路看作自编码器,尝试用神经网络联合学习发送和接收过程^[10];随后,研究者开始关注真实空口训练、无显式信道模型学习以及神经网络接收机等问题^[11,31];近几年,研究重点逐渐转向与

标准物理层的兼容，例如在正交频分复用（Orthogonal Frequency Division Multiplexing, OFDM）资源网络上联合完成信道估计、均衡和软信息恢复^[13,14,32,33]。OFDM通过多个正交子载波并行承载数据，能够降低多径信道对单个高速数据流的破坏，是本文仿真链路和真实空口链路的重要基带传输方式。

从工程角度看，完全替换传统物理层并不是最稳妥的路线。低密度奇偶校验码（Low-Density Parity-Check Code, LDPC）、正交幅度调制（Quadrature Amplitude Modulation, QAM）和OFDM导频估计等方法已有成熟理论基础和标准化支撑^[34-37]。LDPC用于在比特层面提供纠错冗余，QAM用于把比特组映射为复平面上的星座点，导频估计则用于根据已知参考符号恢复信道状态。因此，更可行的方式是选择物理层中的关键环节进行渐进式替代：先替换调制映射或软解调估计，再进一步研究可训练星座、信道估计补偿和真实接收前端。本文的系统设计正是沿着这条路线展开。

1.1.3 端侧AI与真实链路验证研究

边缘计算把计算任务尽量放到数据源附近，以减少回传数据量和响应等待^[15]。深度学习模型一旦落到端侧设备，问题就不只剩下识别精度或重建质量，还包括推理速度、显存管理、数据搬移和连续运行稳定性^[16]。放到语义通信场景里看，这一点更直接：模型可以压缩图像，但如果每帧处理都拖得太久，实时链路仍然跑不起来。

真实链路验证也是当前研究中的关键缺口。理想仿真信道能够提供可控条件，但真实复基带链路会引入频偏、相位旋转、幅度漂移和噪声非平稳等因素。神经网络在这种环境下不一定自动有效，仍然需要导频同步、信道估计和均衡等传统方法提供支撑。本文因此将真实复基带接收前端作为系统的一部分，而不是把它放在通信链路之外讨论。

1.2 本文主要研究内容

围绕端侧图像语义通信的实际需求，本文聚焦一条清晰的研究主线：如何在边缘计算设备上构建兼具语义压缩、可靠传输、神经物理层替代和真实链路适配能力的通信系统。与单纯算法仿真不同，本文更关注系统从图像输入、语义表征、物理层传输到接收端重建的完整闭环，以及该闭环在边缘设备和真实空口条件下的可运行性。本文研究内容之间的关系如图1.1所示，具体工作包括以下几个方面。




图 1.1 本文研究内容与系统闭环关系

第一，构建端侧图像语义通信链路。发送端将图像映射为潜变量表示，通过重要性选择和量化降低传输负载，再结合信道编码和复数符号映射形成可传输序列；接收端完成软信息恢复、信道译码、反量化和语义重建。该部分对应本文系统的主体链路，也是后续神经物理层和边缘端优化的基础。

第二，研究神经网络对传统物理层模块的替代方式。本文保留可靠信道编码作为基准支撑，重点设计神经调制、软解调和可训练星座图。这样既能够观察神经网络在物理层中的学习能力，也便于与传统QAM和软判决解调进行对比分析。

第三，设计真实复基带接收前端。复基带信号 (Complex Baseband Signal) 使用同相分量和正交分量表示无线信号的幅度与相位，是数字基带处理和射频收发之间的核心信号形式。面对真实链路中的相位旋转、增益漂移和星座扩散，本文引入导频同步、信道估计、均衡和残差补偿等前端处理方法，使接收符号尽量回到可解调的几何结构上。这个部分直接服务于通用软件无线电外设 (Universal Software Radio Peripheral, USRP) 真实空口传输验证；USRP在本文中用于完成数字基带数据与真实射频信号之间的转换，是连接仿真链路和真实无线环境的关键硬件平台。

第四，分析边缘端运行代价。本文把语义模型推理、量化、物理层批处理、链路传输和语义重建纳入同一套时延分析框架，讨论边缘GPU上实时运行的瓶颈和优化方向。系统评价不只看链路能否完成闭环传输，也关注连续性、稳定性和端侧低时延能力。

1.3 本文结构安排

全文共分为五章，各章内容安排如下。

第一章为绪论，主要介绍端侧语义通信的研究背景、国内外研究现状、本文研究内容和章节结构，为后续理论分析和系统设计提供研究问题来源。

第二章为相关技术与理论分析，重点分析语义通信、图像潜变量表示、LDPC编码、QAM软解调、OFDM导频估计、神经物理层和边缘端AI部署等理论基础。

第三章为端侧神经语义通信系统设计，围绕本文实际完成的语义收发链路、基于神经网络的调制与软解调、可训练星座图、真实复基带接收前端和边缘端优化方法展开系统设计。

第四章为实验与分析，给出端侧语义链路、神经物理层替换、可训练星座、真实接收前端和端侧时延的实验设计、评价指标与结果分析。

第五章为总结与展望，总结全文工作、归纳主要特点，并从语义质量评价、物理层泛化能力和端侧系统集成等角度给出进一步研究方向。

第2章 相关技术与理论分析

2.1 引言

本章介绍本文涉及的相关技术与理论基础。图像语义通信系统并不是由单一模型或单一通信模块构成，而是由语义表示、信道编码、调制解调、多载波传输、真实空口前端和端侧推理共同支撑。只有先明确这些技术各自解决的问题，后续系统设计中的模块划分和实验指标才具有清晰依据。

本章首先介绍语义通信与图像潜变量表示，说明图像内容如何从像素空间转换为更适合传输的语义载体；随后分析LDPC编码、QAM软解调、OFDM传输和导频估计等可靠物理层基础；接着讨论神经网络进入物理层后的作用方式，包括神经调制、神经软解调和可训练星座图；最后介绍边缘计算加速理论、软件无线电平台以及真实空口链路中常见的信道损伤。上述内容共同构成本章的理论基础，为第三章系统结构设计和第四章实验分析提供支撑。

2.2 语义通信与图像潜变量表示

语义通信的出发点并不是简单地把传统通信系统中的某个模块替换成神经网络，而是重新审视传输内容和评价标准这两个问题。对于图像业务而言，像素级数据量大、冗余高，而且相邻像素之间存在很强的空间相关性。如果仍然把每一个像素值都视为同等重要的信息单元，系统很容易在带宽和时延上付出较高代价。语义通信则更关注图像中对人眼观察或机器感知有价值的结构信息，例如物体轮廓、纹理区域、空间布局和颜色分布。

在本文系统中，语义表示不是一个抽象概念，而是与后续物理层传输直接相连。发送端先把图像压缩到潜变量空间，再从潜变量中选择更重要的分量进行量化和信道编码；接收端则在恢复语义比特后重建图像。这里的潜变量（Latent Variable）是指神经网络在隐空间中形成的低维连续表示，它不直接对应某一个像素，却承载了图像结构、纹理和颜色分布等可用于重建的关键信息。因此，本节先讨论语义有效性，再分析变分自编码器（Variational Autoencoder, VAE）潜变量与重要性选择的作用。VAE在本文中用于完成图像语义压缩和重建，是连接图像内容与物理层比特传输的核心模型。这样的顺序能够说明：后续物理层并不是在传输普通比特流，而是在保护一组经过语义压缩后的关键表示。

2.2.1 从比特可靠性到语义有效性

传统通信系统通常把信源转换为比特流，再通过信道编码和调制完成传输。接收端的目标是尽可能恢复发送端比特，因此误码率、块错误率和吞吐量成为常用评价指标^[1,3,38]。这种方法适用于文件、控制消息和严格格式化数据，因为比特错误会直接破坏接收结果。

图像语义通信的目标有所不同。接收端并不追求逐像素复原原图，而是希望恢复主要目标、轮廓、纹理和场景关系。若系统用于观察或智能感知，语义可用性有时比比比特完全一致更重要。Xie等^[7]将深度学习引入语义通信系统建模，Weng和Qin^[39]进一步将语义通信思想用于语音传输任务，Lan等^[20]从机器智能时代意义传递的角度梳理了语义通信的内涵。国内方面，张平等^[4]将语义通信概括为面向未来通信的新型编码传输范式，强调其核心并非简单减少数据量，而是在语义层面提高信息传输效率。由此可见，语义通信的评价思路正在从单一误码率扩展到语义保真、任务有效性和资源效率的综合分析。

从系统设计角度看，语义有效性并不排斥比特可靠性。相反，二者是分层关系：物理层仍需要尽量降低误码，语义层则进一步判断这些误码是否会破坏图像中的关键信息。举例来说，潜变量中某些分量可能只影响局部纹理，另一些分量则可能决定目标轮廓和整体色调。若传输资源有限，系统更希望优先保护后者。这一思想正是本文采用重要性选择和分段传输的理论依据。

可以用一个抽象模型描述语义通信。设原始信源为 $\mathbf{x}$ ，语义编码器将其映射为潜在表示 $\mathbf{z}$ ，信道输出为 $\mathbf{y}$ ，接收端根据 $\mathbf{y}$ 恢复 $\hat{\mathbf{x}}$ 或任务结果 $\hat{\mathbf{u}}$ 。系统优化目标不再只是最小化比特错误，而是更关注

$$\min \mathcal{D}_{\text{sem}}(\mathbf{x}, \hat{\mathbf{x}}) \quad \text{or} \quad \max \mathcal{A}(\mathbf{u}, \hat{\mathbf{u}}), \quad (2.1)$$

其中 $\mathcal{D}_{\text{sem}}(\cdot)$ 表示语义失真， $\mathcal{A}(\cdot)$ 表示任务一致性或任务准确率。这个表达式并不意味着传统误码指标不重要，而是说明误码指标需要和语义质量共同分析。

2.2.2 变分自编码器与潜变量压缩

VAE是一类常用的潜变量生成模型，其基本思想是把输入数据映射到隐空间分布，再从隐空间中恢复原始数据^[40]。对于图像语义通信而言，潜变量的价值在于：它通常比像素空间更紧凑，而且能够保留图像结构信息。若发送端只传输重要潜变量，链路负载就有机会降低。

与普通降维方法相比，VAE更适合用来解释本文的图像语义链路。其编码端输出的不是一组孤立特征，而是具有分布约束的潜变量；解码端则利用这些潜变量重建图

像。这个结构与通信系统天然相似：编码端负责提取可传输表示，信道负责承载该表示，解码端负责恢复可理解内容。也正因为如此，VAE潜变量可以被视为图像语义信息进入物理层之前的中间载体。

需要注意的是，潜变量压缩并不等于无损压缩。VAE在训练时允许一定重建误差，以换取更平滑、更紧凑的隐空间结构。对于端侧语义通信来说，这种特性反而有工程价值：系统不必传输完整像素，而是传输足以重建主体内容的低维表示。后续物理层只需保护这部分表示，链路负担随之降低。

设编码器给出近似后验 $q_\phi(\mathbf{z}|\mathbf{x})$ ，解码器给出 $p_\theta(\mathbf{x}|\mathbf{z})$ 。训练目标中的库爾貝克-萊布勒散度（Kullback-Leibler Divergence, KL散度）用于度量两个概率分布之间的差异，在这里主要约束潜变量分布不要偏离预设先验。训练目标通常可写为

$$\mathcal{L}_{\text{vae}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[-\log p_\theta(\mathbf{x}|\mathbf{z})] + D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z})), \quad (2.2)$$

其中第一项约束重建质量，第二项约束潜变量分布。KL散度在本文中的作用是使隐空间分布更加规整，避免潜变量过度分散，从而便于后续选择、量化和重建。这个训练目标带来一个重要启发：语义通信并不一定要传输所有像素，而可以传输更紧凑的潜变量表示。图像压缩领域的相关研究也表明，概率建模和潜变量分布约束能够显著提高压缩效率^[41]。

在本文系统中，VAE潜变量还承担了连接AI模型与通信链路的作用。图像经过语义编码后不再以二维像素矩阵形式直接进入物理层，而是变成一组可选择、可量化、可分段保护的连续数值。这使得后续LDPC编码、调制映射和真实空口传输能够围绕语义压缩后的表示展开，而不是围绕原始图像本身展开。

2.2.3 重要性选择与量化误差

潜变量进入物理层之前通常需要经过选择和量化。选择过程决定哪些语义分量被传输，量化过程决定连续潜变量如何变成有限比特。设潜变量向量为

$$\mathbf{z} = [z_1, z_2, \dots, z_N], \quad (2.3)$$

重要性集合为 $\mathcal{K}$ ，则被传输的潜变量可表示为

$$\mathbf{z}_{\mathcal{K}} = \{z_i \mid i \in \mathcal{K}, |\mathcal{K}| = K\}. \quad (2.4)$$

若采用 B 比特量化，量化值 q_i 可抽象表示为

$$q_i = \mathcal{Q}_B(z_i; z_{\min}, z_{\max}), \quad i \in \mathcal{K}. \quad (2.5)$$

图2.1概括了上述过程。从图像语义编码开始，系统先在潜变量空间中形成更紧

凑的表示，再经过重要性选择和量化进入无线链路；接收端则根据恢复出的潜变量完成语义重建。该图强调的不是某一个单独公式，而是语义表示、数字化处理和物理层传输之间的衔接关系。




图 2.1 图像潜变量语义传输理论示意图

重要性选择的工程意义在于控制链路负载。虽然潜变量已经对原始图像进行了压缩表示，但其维度通常仍然较高；若全部传输，仍会占用较多链路资源，从而削弱语义压缩带来的收益。前K大选择（Top-K Selection, Top-K选择）可以把有限的传输资源集中到幅值较大或贡献更突出的潜变量分量上，从而在有限带宽下尽可能保留图像主体结构 and 关键语义信息。Top-K在本文中不是分类意义上的排序指标，而是端侧语义压缩中的资源分配机制：它决定哪些潜变量进入无线链路，哪些分量由接收端重建模型进行补全。当然，这种选择在降低传输负载的同时也会引入一定信息丢失，因此它本质上是一种资源受限条件下的语义取舍。

量化则是潜变量进入数字通信链路的必要步骤。连续潜变量无法直接送入信道编码器，必须先映射为有限比特表示。量化位宽越高，潜变量保真度越好，但每一帧需要传输的比特数也越多；量化位宽越低，链路压力下降，但接收端语义重建可能出现细节不足。本文选择把重要性选择和量化放在同一节讨论，正是因为二者共同决定了语义信息的传输规模和数值精度。

量化带来的误差会在接收端语义重建时传播。如果 B 过小，潜变量精度不足，重建图像容易出现纹理丢失；如果 B 过大，传输负载增加，物理层误码风险也会提高。这就形成了一个典型折中：语义压缩越强，传输压力越小，但语义恢复越依赖模型的补全能力。第三章中的重要性选择和分段传输设计，正是围绕这一折中展开。

2.3 可靠无线物理层理论基础

语义表示解决传输内容问题，可靠物理层解决传输可靠性问题。在本文系统中，VAE潜变量经过选择和量化后形成语义比特，这些比特仍然需要面对无线信道中的噪声、衰落、同步偏差和硬件非理想。若物理层保护不足，即使语义编码本身有效，接收端也可能因为关键比特错误而无法完成稳定重建。

因此，本节并不追求对通信理论进行完整推导，而是选取与本文链路最相关的三个基础环节进行分析：LDPC编码提供纠错能力，QAM星座与软解调决定比特到复数符号及软信息的转换方式，OFDM与导频估计则为真实复基带链路提供多载波传输和接收同步基础。它们共同构成本文神经物理层替代的基准框架。

2.3.1 LDPC编码与软判决译码

低密度奇偶校验码是一类由稀疏校验矩阵定义的线性分组码，具有接近信道容量的纠错能力^[34,35,42]。设校验矩阵为 $\mathbf{H}$ ，合法码字 $\mathbf{c}$ 需满足

$$\mathbf{H}\mathbf{c}^T = \mathbf{0}. \quad (2.6)$$

在接收端，译码器通常不只使用硬判决结果，而是利用每个比特为0或1的置信度。该软信息通常用对数似然比（Log-Likelihood Ratio, LLR）表示。LLR的符号反映比特更可能为0还是1，幅值则反映判决置信度，因此它比硬判决比特更适合输入后续译码器：

$$L(b_i) = \log \frac{P(b_i = 0|\mathbf{y})}{P(b_i = 1|\mathbf{y})}. \quad (2.7)$$

软判决信息越准确，译码器越容易判断哪些比特可靠、哪些比特需要纠错。对本文而言，神经解调器的核心任务并不是简单输出0或1，而是输出能够被译码器利用的可靠LLR软信息。

这也是LDPC与神经解调之间最关键的接口关系。发送端的语义比特经过LDPC编码后具有冗余保护，接收端译码器则需要来自解调器的软信息作为输入。如果神经解调器能够更好地刻画接收符号与比特置信度之间的关系，LDPC译码就可以获得更可靠的先验信息。换言之，本文并不是用神经网络取代全部纠错机制，而是让神经网络服务于软信息估计，使成熟信道编码仍然发挥作用。

2.3.2 QAM星座与软解调模型

QAM调制通过复平面上的星座点承载多个比特，是数字通信系统中常用的高阶调制方式^[38,43]。这里的星座图指由一组复数点构成的调制映射图，每个点对应一个固定比特标签；接收端根据接收样本落在复平面中的位置，判断其更可能来自哪个星座点。设每个符号承载 m 个比特，星座集合为 $\mathcal{S}$ ，发送符号 $s \in \mathcal{S}$ ，接收端观测为

$$y = s + n, \quad n \sim \mathcal{CN}(0, \sigma^2). \quad (2.8)$$

在加性高斯噪声条件下，第 j 个比特的软信息可由不同星座子集的距离加权得到：

$$L_j(y) = \log \frac{\sum_{s \in \mathcal{S}_{j,0}} \exp(-|y - s|^2 / \sigma^2)}{\sum_{s \in \mathcal{S}_{j,1}} \exp(-|y - s|^2 / \sigma^2)}, \quad (2.9)$$

其中 $\mathcal{S}_{j,0}$ 和 $\mathcal{S}_{j,1}$ 分别表示第 j 个比特为0和1的星座点集合。式(2.9)体现了传统软解调的优势：模型清晰、计算可解释。但它也依赖噪声模型和星座几何假设。一旦真实链路扰动偏离假设，软信息尺度可能出现偏差。

在本文中，传统QAM不仅是基准调制方式，也是分析神经物理层改进效果的参照对象。标准QAM星座具有规则几何结构，便于实现、解释和比较；神经调制、神经解调以及可训练星座的价值，正是在这一基准上体现出来。若接收星座受到真实空口扰动而出现旋转、扩散或非均匀压缩，传统软解调仍按照固定几何距离计算置信度，此时神经网络对非线性边界和软信息尺度的学习能力就具有实际意义。

2.3.3 OFDM、导频与信道估计

OFDM通过多个正交子载波并行传输数据，能够有效缓解频率选择性衰落^[36,44,45]。在实际基带处理中，发送端通常利用逆快速傅里叶变换（Inverse Fast Fourier Transform, IFFT）把频域子载波符号转换为时域采样序列，接收端再利用快速傅里叶变换（Fast Fourier Transform, FFT）恢复频域符号。IFFT/FFT使多载波调制可以高效实现，是本文OFDM链路中的基础变换。设频域符号为 $X[k]$ ，时域符号为

$$x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k] \exp\left(j \frac{2\pi kn}{N}\right). \quad (2.10)$$

接收端若要恢复数据子载波，需要估计信道频响。导频估计的基本形式可写为

$$\hat{H}[k_p] = \frac{Y[k_p]}{X[k_p]}, \quad k_p \in \mathcal{P}, \quad (2.11)$$

其中 $\mathcal{P}$ 表示导频子载波集合。导频估计看似简单，却是连接真实复基带链路和语义重建的关键环节。如果星座点在接收端已经严重旋转或扩散，后续神经解调和语义恢复

都会受到影响。

对于本文的真实空口验证而言，OFDM和导频的意义还体现在系统可控性上。神经网络可以学习复杂映射，但它并不能自动消除所有硬件偏差；接收端仍需要利用导频完成同步、信道估计和均衡，使接收符号尽量回到可判决的复平面结构。可以说，导频处理为神经物理层提供了更稳定的输入条件，而神经模块则在此基础上进一步改善调制映射或软信息恢复效果。

2.4 神经网络物理层替代理论

传统物理层的优势在于结构清晰、理论成熟，但其模块边界通常由人工设计的数学模型固定下来。神经网络物理层的核心思想，是把其中某些难以精确建模或容易受实际信道影响的环节转化为可训练映射。这里的替代并不意味着抛弃传统通信理论，而是在标准链路框架内引入可学习参数，使系统在复杂信道和硬件扰动下具有更强的适配能力。

本文关注的神经物理层主要围绕调制、解调和星座几何展开。调制器决定比特组如何落到复平面，解调器决定接收符号如何转化为软信息，星座图则把这种映射关系以可观察的几何形式表现出来。因此，可训练星座图并不应理解为与神经调制/解调完全并行的另一条路线，而是神经物理层中更轻量、更直观的一种参数化表达。它使模型学习结果能够通过星座点坐标、聚类间距和接收分布被直接观察。

2.4.1 通信自编码器与可训练收发机

通信自编码器将发送端、信道和接收端看作一个整体优化系统^[10,11,31]。设发送端映射为 $f_\theta(\cdot)$ ，信道为 $\mathcal{H}(\cdot)$ ，接收端映射为 $g_\phi(\cdot)$ ，则端到端过程可表示为

$$\hat{\mathbf{b}} = g_\phi(\mathcal{H}(f_\theta(\mathbf{b}))). \quad (2.12)$$

训练目标通常是最小化发送比特 $\mathbf{b}$ 与恢复比特 $\hat{\mathbf{b}}$ 之间的差异。该思想说明，调制、信道适配和接收判决可以通过数据共同优化。不过，真实系统中信道可能不可微、训练数据可能有限，完全端到端替代并不总是可行。因此，本文采用渐进替代路线：保留可靠编码和标准物理层基准，重点替换调制映射、软解调估计和星座几何。

这种渐进式思想更适合端侧语义通信系统。原因在于，本文系统不仅要验证某个神经模块的误码率，还要让语义编码、信道编码、真实空口和边缘端推理协同工作。若一次性替换全部物理层模块，系统可解释性和调试难度都会显著增加；而保留LDPC、OFDM和导频估计等成熟环节，则可以把研究重点集中在最能体现神经网络优势的非线性映射和软信息恢复上。

2.4.2 神经调制与神经软解调

神经调制器的目标是学习从比特组到复数符号的映射。与规则QAM相比，神经调制不必严格满足方形星座结构，可以根据训练目标形成更灵活的几何分布。神经软解调器的目标则更复杂，它不仅需要判断符号最接近哪个比特组合，还要输出可供译码器使用的软信息。现有神经接收机研究表明，卷积结构、图结构和注意力结构都可用于联合建模信道估计、均衡和软信息恢复^[13,14,32,33]。

需要强调的是，神经解调器输出的软信息必须和信道译码器相匹配。若软信息方向正确但置信度尺度不合适，译码器仍可能被误导，从而影响最终译码结果。这一点也是系统实验需要重点观察的问题。换一种更直观的说法，接收端不仅要判定比特取值，还要给出足够可信且尺度合理的判定强度。

2.4.3 可训练星座图的参数化解释作用

神经调制/解调的内部特征通常不容易直接观察，而星座图恰好提供了一个直观的分析窗口。每一个星座点都对应一个比特组，点间距离、整体功率、坐标分布和接收端聚类形态都能反映物理层映射的性质。将星座点坐标设为可训练参数后，系统可以在保持“比特组到复数符号”这一传统接口不变的前提下，使星座几何结构根据训练目标进行自适应调整，从而增强映射方式与信道环境之间的匹配性。

因此，本文中的可训练星座图更适合被看作神经物理层的参数化显示层。它不像完整神经调制器那样把映射完全隐藏在高维网络内部，而是把可学习结果落到复平面上的有限点集上。这样既便于与标准16QAM进行对比，也便于在真实空口实验中通过接收星座的聚类效果观察优化收益。设星座点为

$$s_i = a_i + jb_i, \quad i = 1, 2, \dots, M, \quad (2.13)$$

其中 a_i 和 b_i 是可训练参数， M 为星座阶数。优化过程中通常需要加入平均功率约束和点间距约束，以避免星座整体漂移或点位过度聚集。经过训练后，星座点的变化并不是单纯的图形美化，而是传输目标、噪声模型和判决边界共同作用的结果。对本文而言，这种可视化参数形式具有两点价值：一是可以作为神经调制思想的轻量化落地方式，二是可以为真实空口下的星座聚类分析提供清晰的图形证据。

2.5 边缘计算与端侧AI加速理论

语义通信系统若只在离线环境中获得较好重建效果，还不能说明其适合端侧应用。端侧设备通常受到功耗、显存容量、散热条件和实时帧率的共同限制。尤其在图像语义通信中，发送端需要完成图像语义编码、潜变量选择、量化和物理层映射，接

收端还要完成软信息恢复、译码和图像重建。任何一个环节的延迟过高，都会影响系统连续运行。

因此，边缘计算理论在本文中不是附加内容，而是系统设计能否落地并稳定运行的重要支撑。与服务器端追求峰值吞吐不同，端侧部署更关注单帧时延、显存复用和计算调度稳定性。下面从计算图编译、精度降维和推理引擎映射三个角度说明端侧加速的基本原理。

2.5.1 计算图编译与算子融合理论

端侧AI系统的时延并不只由算术运算量决定。对于通信物理层中的复数乘法、向量归一化、矩阵运算和傅里叶变换等细粒度操作，单个算子的计算量并不大，但大量小算子串联会带来频繁调度、显存读写和中间张量搬移开销。瓶颈有时并不来自算力不足，而来自执行组织不够紧凑。这也是边缘GPU部署与服务器离线评估之间最容易被忽略的差异。

静态计算图编译的基本思想，是在运行前或预热阶段确定数据流关系，将多个相邻算子重排、融合并映射到更适合硬件执行的计算子图中。算子融合可以减少中间结果写回显存的次数，也能降低主处理器与图形处理单元之间的调度开销。对于本文所涉及的语义编解码、软信息恢复和批量物理层处理而言，计算图优化的价值不在于改变数学模型，而在于以更低的调度成本完成同一组张量运算。这个理论基础直接对应第三章中的边缘端实时部署设计。

在通信链路中，批量化也可以看作计算图优化的一部分。同一帧图像被分成多个语义分段后，如果逐段独立处理，会反复触发调度和数据搬移；若把多个分段组织为批量张量，则可以提高硬件并行度，并减少端侧运行时的固定开销。本文第三章和第四章中关于TX/RX端时延优化的分析，正是建立在这一理论基础之上。

2.5.2 精度降维与显存带宽管理

边缘设备上，很多时候先卡住的不是计算单元，而是显存带宽。常规32位浮点数(32-bit Floating Point, FP32)每访问一次就要搬运4个字节，精度充足，训练和高精度计算都离不开它；可到了端侧推理，频繁读写会很快把带宽占满。图像语义编解码又包含大量大尺寸特征图，卷积层之间还会产生不少中间结果。计算单元明明有余量，却在等待数据，这种情况在边缘GPU上并不少见。

精度降维的价值，主要体现在搬运数据少了、低精度计算单元也能用起来。模型权重和中间激活从FP32换成16位浮点数(16-bit Floating Point, FP16)后，同样一批数据占用的带宽大约减半；边缘GPU中的张量核心也更容易被调度到矩阵乘加任务上。FP16在本文中只服务于推理加速，不改变语义通信链路的模型含义。实际空口本身存

在噪声和衰落，只要半精度误差没有超过系统可接受范围，用少量数值精度换取时延下降就是值得考虑的工程折中。

精度降低也不能只盯着速度。潜变量幅值、物理层软信息尺度和译码输入置信度都比较敏感，数值处理过粗可能让后续判决出现偏移。因此，端侧加速需要分清对象：卷积、矩阵乘法这类计算密集环节优先低精度执行；概率、归一化和软信息尺度相关环节则保留足够稳定的数值表示。本文后续实验也遵循这个边界，只在不破坏链路可用性的前提下做加速。

2.5.3 推理引擎执行映射与零拷贝机制

在加速理论的更底层，是将计算图映射到特定硬件执行计划的过程。高性能推理引擎通常会根据边缘GPU的计算单元数量、缓存层级、显存带宽和支持的数据精度，为不同算子选择合适的执行策略。对于卷积、矩阵乘法和归一化等高频操作，推理引擎会在满足数值精度约束的前提下选择更快的算法路径，并尽量复用中间缓存。这样做的直接结果，是推理过程从逐层临时调度转变为按固定执行计划连续推进。

端侧设备还常采用统一内存或共享内存架构，数据搬移方式会显著影响实时链路稳定性。若每一帧语义潜变量都在不同处理单元之间反复复制，系统吞吐会被内存带宽限制。较优的执行映射应尽量保持输入、输出和中间张量在连续缓冲区中复用，并减少不必要的数据格式转换。对本文系统而言，这类机制的意义很明确：在不改变通信算法本身的情况下，降低语义重建和接收端软信息恢复的端侧时延。

从论文主线来看，端侧AI加速为语义通信系统提供了工程闭环。语义编码降低了无线传输负载，神经物理层提高了映射适配能力，而端侧推理优化则保证这些模块能够在边缘GPU上连续运行。三者结合，才构成本文关注的端侧语义通信系统，而不是单纯的算法仿真。

2.6 软件无线电与空口信道特性

2.6.1 软件无线电与USRP工作原理

软件无线电（Software Defined Radio, SDR）的核心思想是将硬件部分尽可能集中在射频收发和数模转换环节，而把基带处理尽可能交给软件完成。传统的硬件通信机将调制解调、滤波和信道编解码固化在专用集成电路（Application Specific Integrated Circuit, ASIC）中，难以灵活更改。而SDR系统仅保留射频前端（Radio Frequency Front-End, RF Front-End）、模数转换器（Analog-to-Digital Converter, ADC）和数模转换器（Digital-to-Analog Converter, DAC）作为硬件基底，将所有复基带信号处理过程移交至上位机通过通用处理器或GPU计算。RF前端负责射频信号的放大、混频和滤波，

ADC/DAC则负责模拟信号与数字采样序列之间的转换。

通用软件无线电外设 (Universal Software Radio Peripheral, USRP) 是典型的SDR硬件平台之一。在本文涉及的发射链路中, 边缘端产生复数基带符号序列, 并通过高速数据接口送入USRP; USRP内部进一步完成数字上变频、插值滤波、数模转换和射频上变频。接收链路则执行相反过程: 射频信号经过低噪声放大、下变频和模数转换后形成数字基带同相/正交 (In-phase/Quadrature, IQ) 数据, 再交由边缘端完成同步、均衡、解调和语义恢复。IQ数据用两个正交分量表示复基带采样, 是本文进行星座分析和软解调处理的直接输入。这种软硬件解耦的架构, 为可训练物理层模块进入真实无线链路提供了实验条件。

2.6.2 理想仿真信道与真实空口的差异

在理论仿真中, 研究者常使用加性高斯白噪声 (Additive White Gaussian Noise, AWGN) 或理想瑞利衰落 (Rayleigh Fading) 信道模型。AWGN信道假设信号仅受到零均值高斯噪声叠加, 适合用作物理层算法的基础可控基准; 理论衰落模型通常还隐含较理想的时频同步条件。真实空口链路则更复杂, 它同时受到硬件损伤、空间传播和环境噪声的影响。也就是说, 仿真模型给出了可控基准, 真实链路则检验系统的综合鲁棒性。

一个关键因素是收发双端独立晶振引发的载波频偏。即使收发设备设定相同载波频率, 实际本振仍可能存在百万分率量级偏差, 进而使接收星座产生持续相位旋转。另一个因素是射频前端的非线性与I/Q不平衡, 它会造成星座点幅度压缩、相位扭曲和聚类中心偏移。室内环境中的多径反射还会引入频率选择性衰落, 使理想平坦信道假设受到挑战。因此, 真实空口系统需要导频、同步、信道估计和均衡等机制参与协同, 神经网络物理层也应放在这一链路约束下分析, 而不是脱离接收前端单独评价。

2.7 本章小结

本章从语义表示、可靠物理层、神经替代、端侧部署以及空口信道五个维度分析了本文研究所需的理论基础。首先, 语义通信把优化目标从比特完全一致扩展到语义有效性, VAE潜变量与重要性选择为图像语义压缩提供了理论支撑。其次, LDPC编码、QAM软解调和OFDM导频估计构成了可靠传输的底层逻辑, 也为后续神经模块提供了性能参照。接着, 本章说明了神经网络替代物理层的合理性与边界: 基于神经网络的调制与软解调能够学习复杂的非线性映射, 而可训练星座则在抗畸变与可解释性之间取得折中。

进一步地, 从边缘GPU的计算图编译与精度降维理论说明了端侧实时部署的加速

潜力；最后，剖析了SDR架构原理以及真实空口非理想硬件损伤对理想通信模型的破坏，论证了引入导频同步与频偏估计的必要性。这些理论和现实约束，为下一章端侧系统全链路的工程设计指明了方向。

第3章 端侧神经语义通信系统设计与实现

3.1 引言

第二章从理论层面分析了语义表示、可靠物理层、神经物理层替代和端侧部署问题。本章在此基础上给出本文系统的具体设计。与单纯的算法验证不同，本文构建的是一条面向端侧设备的图像语义通信链路：发送端提取图像语义潜变量并形成可传输比特，物理层完成编码和复数符号映射，接收端完成软信息恢复、译码、反量化和图像重建。神经网络模块则被嵌入调制、软解调、星座几何和接收前端补偿等环节。

本章围绕系统模块展开，主要内容包括端侧语义收发链路、基于神经网络的调制与软解调模块、可训练星座图、真实复基带接收前端以及边缘GPU运行优化。图像首先被压缩为可传输的语义表示，随后经过信道编码和物理层映射进入链路；接收端根据复基带符号恢复软信息，再完成译码、反量化和语义重建。通过这样的模块化设计，第二章讨论的理论基础被组织为一条可运行的端到端链路，并为第四章的仿真、空口和时延实验提供系统对象。

3.2 系统总体架构设计

3.2.1 系统功能划分

本文系统按照语义压缩、信道保护、物理层映射、链路传输和接收重建五个层次进行设计。语义压缩层负责将图像映射为潜变量表示；信道保护层负责将语义比特编码为具有纠错能力的码字；物理层映射层负责将码字转换为复数基带符号；链路传输层负责在端侧设备和接收端之间传递符号序列；接收重建层负责根据软信息恢复语义比特并重建图像。

这种分层方式有两个好处。其一，它保留了传统通信链路中编码、调制、传输、解调、译码的基本边界，使不同物理层方案可以在相同接口下比较；其二，它把语义模型放在信源侧和重建侧，而不是让神经网络无边界地覆盖整条链路。由于每个模块都有明确输入输出，实验中也更容易定位性能变化来自语义压缩、物理层替换还是端侧推理优化。

系统总体架构如图3.1所示。图中虚线部分表示可替换模块：传统QAM映射器可以替换为神经调制器，可训练星座可以替换标准QAM星座，传统最大后验概率（A Posteriori Probability, APP）解映射器可以替换为神经解调器。APP解映射器根据接收符号、噪声估计和星座几何计算比特后验概率，是传统软解调中的常用基准模块。这样设计的好处是链路可分阶段验证，不需要一开始就把所有模块同时神经网络化。




图 3.1 端侧语义通信系统总体架构

系统各模块的输入输出关系如表3.1所示。表中同时列出了各模块在系统中的功能来源，便于说明数据形态在链路中的变化。表中的蓝绿红（Blue-Green-Red, BGR）图像帧是摄像头采集后常见的颜色通道排列；开源计算机视觉库（Open Source Computer Vision Library, OpenCV）用于完成图像读取、颜色空间转换和保存等基础视觉处理；NVIDIA TensorRT是面向GPU的高性能神经网络推理引擎，在本文中用于降低VAE编解码的端侧推理时延。套接字（Socket）长连接用于在端侧收发进程之间持续传递基带数据，使实时链路能够按帧组织和恢复。

表 3.1 端侧语义通信系统主要模块及输入输出

模块	输入	输出	实现依据
图像预处理	摄像头BGR帧	$1 \times 3 \times 512 \times 512$ 归一化张量	OpenCV、图像预处理流程
VAE语义编码	归一化图像张量	$4 \times 64 \times 64$ 潜变量	TensorRT编码后端
量化编码	潜变量、量化位宽、Top-K数量	分段语义比特、索引、量化范围	Top-K选择、分位数量化函数
物理层发送	语义比特	复数基带符号	LDPC编码、神经调制
传输链路	复数符号、帧头	接收复数符号	AWGN仿真、Socket长连接、USRP实验链路
接收解调译码	接收符号、噪声估计	恢复语义比特	神经解调、LDPC译码
语义重建	语义比特、帧头元信息	重建潜变量和图像	反量化、VAE解码、后处理和保存

3.2.2 三类链路关系

本文实际形成了三类相互衔接的链路。第一类是端侧语义收发链路，用于验证图像从语义压缩到接收重建的完整流程。第二类是神经物理层训练与评估链路，用于比较传统调制解调、基于神经网络的调制与软解调以及可训练星座图的性能差异。第三类是真实复基带接收前端链路，用于处理USRP接收符号中的相位偏移、信道衰落和噪声扰动。

三类链路的共同连接点是复数基带符号和软判决信息。语义链路需要物理层提供可靠的比特恢复能力；神经物理层需要在相同码字长度和调制阶数下与传统方案比较；真实接收前端则需要把空口接收符号校正到适合解调的几何状态。由此可见，本文系统的设计主线是先构建图像语义链路闭环，再逐步替换物理层模块，最后将链路推进到真实空口环境中验证。

3.3 发送端语义编码与帧组织设计

3.3.1 图像语义潜变量提取

发送端的第一项任务是把原始图像转换为适合无线链路承载的语义表示。原始图像通常包含大量像素级冗余，如果直接进入物理层，不仅比特量大，而且会使后续信道编码和调制承担较高负载。因此，本文先对输入图像进行尺度统一和数值归一化，使其满足语义编码器的输入尺寸与数值范围要求；随后利用VAE编码器将图像压缩到低维潜变量空间。

潜变量提取不是简单的图像压缩格式转换，而是本文语义通信链路的起点。VAE编码器在训练过程中已经学习到图像结构与隐空间表示之间的对应关系，因此输出潜变量能够在较低维度下保留主体轮廓、颜色分布和纹理趋势。设输入图像为 $\mathbf{x}$ ，编码器为 $E_\theta(\cdot)$ ，则潜变量可表示为

$$\mathbf{z} = E_\theta(\mathbf{x}). \quad (3.1)$$

潜变量 $\mathbf{z}$ 不是原始图像的简单降采样，而是经过模型压缩后的语义表示。它保留了重建图像所需的主要结构信息，因此适合在带宽受限条件下传输。

为降低传输负载，系统不会传输全部潜变量，而是根据幅值或重要性排序选取关键分量。设选出的索引集合为 $\mathcal{K}$ ，则发送端实际进入量化流程的潜变量为 $\mathbf{z}_{\mathcal{K}}$ 。这种设计体现了语义通信的基本思路：在有限链路资源下优先保护对重建更重要的信息，而不是平均对待所有像素。

从系统构成角度看，潜变量提取还决定了后续帧组织方式。每一帧图像被压缩后形成固定形状的潜变量张量，随后再被展开、选择、量化并分段送入物理层。也就是

说，发送端并不是直接传输完整图像数据，而是将经过语义模型整理后的连续数值表示交给物理层处理。这一点使本文链路区别于普通图像传输，也为后续端侧时延分析提供了清晰边界。

3.3.2 Top-K选择与分位数量化

Top-K选择用于确定每一帧中被传输的关键潜变量。它的设计动机来自第二章所讨论的语义取舍：在链路资源有限时，不同潜变量分量对最终重建效果的贡献并不完全相同。若全部潜变量都进入无线链路，语义压缩带来的负载优势会被削弱；若选择过少，接收端重建又可能缺乏必要结构信息。因此，本文通过选择比例控制语义信息量与传输负载之间的平衡。

若潜变量总数为 N ，每帧选择 K 个分量，则选择比例为

$$\rho = \frac{K}{N}. \quad (3.2)$$

ρ 越小，传输负载越低，但重建图像对模型补全能力的依赖越强。本文系统通过分段方式承载潜变量比特，使单帧语义信息能够被拆分为多个物理层码字。

对选中的潜变量，系统采用基于范围归一化的均匀量化思想。量化的作用是把连续潜变量转换为有限比特，使其能够进入LDPC编码和后续调制映射。这里需要保留每帧或每段的尺度信息，因为接收端仅凭量化索引无法知道原始潜变量的取值范围。设量化位宽为 B ，量化等级数为 2^B ，潜变量 z_i 对应的量化索引可抽象表示为

$$q_i = \left\lfloor \frac{z_i - z_{\min}}{z_{\max} - z_{\min}} (2^B - 1) \right\rfloor, \quad i \in \mathcal{K}. \quad (3.3)$$

量化后， q_i 被展开为二进制比特并进入信道编码。为了让接收端能够恢复量化范围，发送端还需要在帧信息中保留必要的尺度参数。这里的关键不是记录更多信息，而是在传输开销和反量化精度之间取得平衡。

3.3.3 信道编码与复数符号映射

量化比特进入物理层之前，先进行LDPC编码。该步骤的作用是为语义比特增加纠错冗余，使接收端在存在噪声和符号判决误差时仍有机会恢复原始比特。由于本文传输的是经过选择后的关键潜变量，单个比特错误可能会影响局部重建质量，因此信道编码对语义链路的稳定性仍然重要。

设信息比特为 $\mathbf{b}$ ，编码后码字为 $\mathbf{c}$ ，编码过程可表示为

$$\mathbf{c} = \mathcal{C}_{\text{LDPC}}(\mathbf{b}). \quad (3.4)$$

随后，码字被按每个符号承载 m 比特进行分组，并映射为复数符号序列：

$$\mathbf{s} = \mathcal{M}(\mathbf{c}), \quad \mathbf{s} \in \mathbb{C}^{N_s}. \quad (3.5)$$

其中 $\mathcal{M}(\cdot)$ 可以是传统QAM映射，也可以是神经调制映射。两条路径输出的都是复数基带符号，因此后续帧组织和链路传输保持一致。

这一接口一致性是本文物理层替换设计的关键。发送端无论采用规则星座、可训练星座还是神经调制器，传输层看到的都是复数基带符号序列；接收端也只需要按照对应的解调方式恢复软信息。图3.2展示了发送端从图像输入到复数基带符号输出的处理流程，其中VAE编码、Top-K选择、量化和LDPC编码共同完成语义比特组织，末端的映射模块则为传统QAM、神经调制和可训练星座提供统一接口。




图 3.2 发送端语义编码与物理层映射流程

从图3.2可以看出，发送端设计的重点并不是增加额外链路分支，而是在统一数据边界下保留可替换的物理层入口。这样既能保证链路结构清晰，又能在第四章中对不同替换方案进行公平比较。

3.4 接收端解调译码与语义重建设计

3.4.1 帧解析与软信息恢复

接收端的处理流程与发送端相反，但难度更高。发送端输出的是经过编码和调制的理想符号序列，接收端获得的则是受到噪声、信道扰动和设备非理想影响后的复数符号。因此，接收端首先需要根据帧信息恢复分段边界、量化参数和潜变量索引，确保每一段物理层码字能够回到对应的语义潜变量位置。随后，接收端对复数符号进行软解调，为LDPC译码提供比特置信度。

设接收符号为 $\mathbf{y}$ ，噪声功率估计为 σ^2 ，软解调输出为

$$\mathbf{L} = \mathcal{D}(\mathbf{y}, \sigma^2), \quad (3.6)$$

其中 $\mathbf{L}$ 为软判决信息。 $\mathcal{D}(\cdot)$ 既可以是传统距离度量软解调，也可以是神经软解调。二者的输出都进入LDPC译码器，因此接收端能够在同一套语义重建流程中比较不同物理层方案。

软信息恢复的质量会直接影响后续语义重建。若解调器只给出硬判决，译码器无法区分高置信度比特和低置信度比特；而软信息能够表达置信度，使LDPC译码器在迭代过程中更合理地利用冗余校验关系。因此，本节把软解调放在接收端设计的入口位置，而不是把它视为一个简单的符号判决步骤。

3.4.2 语义比特恢复与反量化

LDPC译码器根据软信息恢复量化比特。该过程将物理层的软判决结果重新转换为语义层可使用的二进制表示，是无线链路和图像重建之间的关键桥梁：

$$\hat{\mathbf{b}} = \mathcal{C}_{\text{LDPC}}^{-1}(\mathbf{L}). \quad (3.7)$$

随后，接收端将比特重新组合为量化索引 $\hat{q}_i$ ，并根据发送端提供的尺度参数进行反量化。反量化的目标不是恢复被舍弃的全部潜变量，而是尽可能准确地还原发送端选择过的关键分量：

$$\hat{z}_i = z_{\min} + \frac{\hat{q}_i}{2^B - 1}(z_{\max} - z_{\min}), \quad i \in \mathcal{K}. \quad (3.8)$$

未传输的潜变量位置采用默认填充值或先验估计补齐，最终得到重建潜变量 $\hat{\mathbf{z}}$ 。这一补齐过程体现了语义通信与传统比特通信的差异：系统承认部分细节没有被显式传输，但依靠VAE解码器的生成能力恢复整体可理解内容。若物理层误差较小，关键潜变量能够被正确恢复，接收端图像通常可以保持较清晰的主体结构；若关键潜变量出现错误，则可能表现为局部纹理异常、色彩偏移或轮廓模糊。

3.4.3 VAE语义重建

接收端语义重建是整条链路的最终输出环节。经过软解调、LDPC译码和反量化后，系统得到的是一个重建潜变量张量，而不是可以直接显示的图像。因此，还需要利用VAE解码器把隐空间表示映射回像素空间。这个过程可以理解为语义信息的图像化恢复：接收端并不是逐项拼回原始像素，而是根据恢复出的潜变量生成一幅视觉上可理解的图像。

接收端通过VAE解码器将潜变量恢复为图像：

$$\hat{x} = G_{\psi}(\hat{z}), \quad (3.9)$$

其中 $G_{\psi}(\cdot)$ 为语义解码器。由于传输的是部分潜变量，并且量化、信道噪声、软解调误差和译码失败都可能在链路中累积， $\hat{x}$ 通常不会逐像素等同于原图。更准确地说，接收端图像是在语义约束下形成的重建结果，它可能牺牲部分细节纹理，却应尽量保留主体结构、场景布局 and 可辨识内容。

这一设计对本文系统具有直接意义。若只关注像素级完全一致，语义压缩和Top-K选择都会显得过于激进；但若目标是使接收端获得可观察、可理解且语义有效的图像内容，那么潜变量重建就具备工程价值。图3.3给出了接收端从复数符号输入到图像恢复的处理流程，重点展示软信息恢复、LDPC译码、反量化、潜变量回填和VAE解码之间的连接关系。第四章中的端到端可视化实验正是围绕这一点展开：通过原图与真实空口重构图并列比较，验证系统已实现图像输入、无线传输与接收端语义重建的端到端闭环。




图 3.3 接收端解调译码与语义重建流程

图3.3中的各步骤与发送端流程一一对应，但接收端多了软信息恢复和潜变量补齐两个关键环节。前者决定LDPC译码能否得到可靠输入，后者决定语义解码器能否在缺失部分潜变量的情况下恢复可辨识图像。

3.5 基于神经网络的调制与软解调模块设计

3.5.1 神经调制器结构

神经调制器用于学习从比特组到复数符号的映射。传统QAM采用固定星座点，优点是结构规则、实现简单，但在训练信道、接收判决和真实链路扰动之间缺少自适应能力。神经调制器的设计目标是在保持比特组输入、复数符号输出这一接口不变的前

提下，让映射关系由数据驱动学习得到。这样既能与传统调制方案保持可比较性，又能为后续神经解调和可训练星座提供更灵活的发送端表示。

其输入为每个符号对应的 m 维比特向量，输出为一个二维实数向量，分别表示复数符号的实部和虚部。为保证平均发射功率稳定，输出符号需要进行功率归一化：

$$\tilde{s}_i = \frac{s_i}{\sqrt{\frac{1}{N_s} \sum_{k=1}^{N_s} |s_k|^2}}. \quad (3.10)$$

在结构上，本文采用多层特征变换、残差连接和上下文建模来增强映射能力。残差连接的作用是让模型在学习非线性映射时保留稳定路径，避免输出过度震荡；上下文建模则用于利用相邻符号之间的统计关系。这样设计不是为了让模型复杂化，而是为了让神经调制在低信噪比和真实扰动下具有更好的适应潜力。

需要指出的是，神经调制器的输出仍然受到功率归一化约束。没有这一约束时，模型可能通过简单增大发射符号幅度来降低训练误差，这在真实通信系统中并不公平，也不符合发射功率受限的工程条件。因此，功率归一化不仅是数学处理步骤，也是保证传统调制与神经调制可比较的必要条件。

3.5.2 神经软解调器结构

神经软解调器接收复数符号和噪声条件，输出每个比特的软判决信息。与发送端调制相比，接收端解调更容易受到信道扰动影响：同一个星座点在不同信噪比、相位偏差和硬件状态下可能呈现不同的接收分布。如果仍然完全依赖固定距离公式，软信息尺度可能与真实置信度不匹配。神经软解调器的作用，就是学习接收符号、噪声条件和比特置信度之间的非线性关系。

设接收符号实部、虚部和噪声特征组成输入向量 $\mathbf{r}_i$ ，则第 i 个符号的软信息可写作

$$\mathbf{L}_i = F_\eta(\mathbf{r}_i), \quad \mathbf{L}_i \in \mathbb{R}^m. \quad (3.11)$$

其中 $F_\eta(\cdot)$ 为神经软解调映射。与硬判决相比，软信息能够表达置信度，因此更适合与LDPC译码结合。本文设计中引入噪声感知分支，使解调器能够根据不同信道条件调整输出尺度。这个设计直接对应第二章中软信息尺度匹配的理论分析。

从系统角度看，神经软解调器并不是独立追求分类准确率的模型。它的输出必须服务于后续LDPC译码，因此更关心软信息是否能够被译码器有效利用，而不只是符号判决是否表面正确。这一点也解释了第四章中为什么要同时比较误块率、误比特率和时延：神经解调的价值需要通过可靠性和工程代价共同判断。

3.5.3 传统模块与神经模块的衔接

为了便于对比，传统物理层和神经物理层在输入输出形态上保持一致。发送端无论采用传统QAM还是神经调制，最终都输出复数符号序列；接收端无论采用传统软解调还是神经软解调，最终都输出LDPC译码所需的软信息。这样，语义层不需要因为物理层切换而改变。

这种设计体现了本文的渐进替代思想。若某个神经模块在某些信道条件下表现不稳定，系统仍可回到传统路径进行对比和验证。更重要的是，这种接口一致性使实验结论更清楚：当第四章中替换某一物理层模块后，语义压缩、LDPC编码、帧组织和重建流程保持不变，性能差异就主要来自被替换模块本身，而不是整条链路的其他变化。图3.4进一步给出了神经调制器与神经软解调器的结构关系。




图 3.4 基于神经网络的调制与软解调模块结构

如图3.4所示，发送端和接收端神经模块通过复数符号和软信息接口相连。该结构保持了与传统QAM和APP软解调相同的输入输出边界，因此能够在不改变语义链路主体流程的情况下完成替换实验。

3.6 可训练星座图与OFDM链路适配设计

3.6.1 可训练16QAM星座参数化

除了完整神经调制器，本文还设计了可训练16QAM星座图。该设计可以理解为神经物理层的一种轻量化表达：它不像完整神经调制器那样把映射关系全部隐藏在网络内部，而是直接把每个比特标签对应的星座点坐标设为可优化参数。这样既能保留传统星座图的可解释性，又能通过训练调整点间距离和空间分布。

其基本思想是保留比特标签与星座点之间的传统对应关系，但允许星座点位置根

据训练目标调整。设第 i 个星座点为

$$s_i = a_i + jb_i, \quad i = 1, 2, \dots, 16, \quad (3.12)$$

其中 a_i 和 b_i 为可训练参数。为避免星座点无约束漂移，训练目标中加入平均功率、中心位置和最小点距等约束。总损失可写为

$$\mathcal{L} = \mathcal{L}_{\text{bit}} + \lambda_1 \mathcal{L}_{\text{power}} + \lambda_2 \mathcal{L}_{\text{center}} + \lambda_3 \mathcal{L}_{\text{dist}}. \quad (3.13)$$

其中 $\mathcal{L}_{\text{bit}}$ 约束比特恢复能力，其余项用于保证星座几何稳定。相比完全自由的神经调制，可训练星座更容易解释，也更适合与真实OFDM链路结合。

这些约束项的存在非常关键。平均功率约束保证训练后星座不会通过整体放大发射能量来获得不公平优势；中心约束防止星座整体偏移，便于接收端同步和判决；最小点距约束则避免不同符号点过度靠近，降低误判风险。也就是说，可训练星座并不是任意改变形状，而是在通信系统可接受的几何边界内寻找更合适的点位分布。

3.6.2 OFDM链路损伤建模

可训练星座在训练过程中需要考虑OFDM链路中的实际扰动，包括导频插入、循环前缀、频偏、相位斜率和信道估计误差。若只在理想AWGN信道中训练星座，得到的点位可能只适合简单噪声模型；一旦进入OFDM链路，子载波映射、同步误差和均衡误差都会改变接收符号分布，进而影响判决稳定性。因此，本文将星座训练与OFDM链路适配放在同一节讨论。

其整体过程可抽象为

$$\mathbf{Y}_{\text{data}} = \mathcal{E}_{\text{ofdm}}(\mathcal{P}_{\text{grid}}(\mathbf{s}, \mathbf{p})), \quad (3.14)$$

其中 $\mathcal{P}_{\text{grid}}(\cdot)$ 表示数据符号和导频符号的资源网格映射， $\mathcal{E}_{\text{ofdm}}(\cdot)$ 表示包含信道扰动和接收均衡的OFDM等效过程。训练星座时考虑这些因素，有助于避免星座只适合理想高斯信道而难以迁移到真实链路。

从第四章的实验组织看，这一设计直接对应两个验证层次：先在仿真OFDM链路中比较标准16QAM和可训练星座的BER，再在USRP真实空口中观察接收星座聚类 and 频域功率分布。前者说明星座训练在可控信道下是否带来可靠性收益，后者则说明这种点位分布能否经受真实射频链路的扰动。图3.5概括了可训练星座与OFDM链路适配的主要流程。

图3.5强调了星座参数、OFDM资源网格和接收判决之间的耦合关系。训练后的星座点并非独立存在，而是要经过子载波映射、导频辅助估计和均衡处理后，才能在接收端形成可判决的符号分布。




图 3.5 可训练星座图与OFDM链路适配流程

3.7 USRP接收前端设计

3.7.1 导频同步与信道估计

真实USRP链路中，接收符号会受到相位旋转、增益变化和噪声扰动影响。如果直接进行解调，星座点往往会出现扩散或整体偏移。对于传统QAM，这会使固定判决边界失效；对于神经解调，输入分布偏移同样会影响软信息输出。因此，本文在接收端加入导频同步和信道估计前端，使进入解调器的符号尽量接近训练和仿真时的几何分布。

设已知导频为 $\mathbf{p}$ ，接收导频为 $\mathbf{y}_p$ ，可先估计公共相位误差：

$$\hat{\varphi} = \arg \left(\sum_i y_{p,i} p_i^* \right). \quad (3.15)$$

相位校正后，再根据信道估计值对数据符号进行均衡。基本信道估计可表示为

$$\hat{h} = \frac{\sum_i y_{p,i} p_i^*}{\sum_i |p_i|^2}. \quad (3.16)$$

该前端的目标不是替代解调器，而是在解调之前尽量校正星座的整体相位、幅度和尺度偏移。只有接收符号几何结构稳定，后续神经软解调和语义恢复才有可靠基础。因此，真实空口系统需要将传统同步估计与神经模块结合起来，降低输入分布偏移，形成更稳定的接收处理链路。

3.7.2 残差补偿前端

在基础同步和估计之后，本文进一步设计了残差补偿前端，用于学习传统估计难以完全描述的细小偏差。实际设备中的非理想因素往往不是单一误差，例如相位偏移

可能伴随幅度漂移，频偏补偿后仍可能存在局部星座拉伸。传统估计可以给出主要校正量，但对这些残余扰动的刻画有限。残差补偿的作用，就是在传统均衡结果基础上做小幅修正。

残差补偿可抽象为

$$\tilde{\mathbf{y}} = \mathbf{y}_{\text{eq}} + R_{\omega}(\mathbf{y}_{\text{eq}}, \hat{h}, \sigma^2), \quad (3.17)$$

其中 $\mathbf{y}_{\text{eq}}$ 为均衡后的符号， $R_{\omega}(\cdot)$ 为残差补偿项。该设计体现了传统方法与神经网络的结合：传统前端提供稳定初值，神经残差负责补偿未建模扰动。这样比直接让神经网络从原始接收符号中学习所有处理过程更稳妥。

从系统设计角度看，残差补偿前端为真实空口链路提供了更细粒度的适配能力。真实USRP链路中的同步、估计和均衡共同决定了后续星座聚类是否具有可解释性，因此接收前端并不是独立于神经物理层之外的辅助环节，而是替换物理层能否稳定进入真实链路的重要条件。图3.6给出了真实复基带接收前端的整体结构。




图 3.6 USRP真实复基带接收前端结构

图3.6中，导频同步用于校正公共相位偏移，信道估计和均衡用于恢复符号尺度与方向，残差补偿则面向传统估计后仍存在的小幅非理想扰动。该流程为后续传统解调、神经解调和可训练星座观测提供了相对稳定的输入。

3.8 边缘端实时部署与优化设计

3.8.1 TensorRT编解码后端推理优化

端侧语义通信的主要延迟瓶颈之一是VAE编码和解码。本文在发送端和接收端分别支持TensorRT engine后端。发送端TensorRT encoder接收 $1 \times 3 \times 512 \times 512$ 图像张量，输出潜变量；接收端TensorRT decoder接收 $1 \times 4 \times 64 \times 64$ 潜变量，输出重建图

像。TensorRT的推理加速依赖多项技术的协同作用。在计算效率方面，TensorRT通过算子融合将卷积、批归一化和激活函数等连续算子合并为更紧凑的底层执行单元，减少GPU启动次数和中间张量的读写开销；同时支持FP16半精度推理，将权重和激活从FP32降至FP16，有效降低显存带宽压力和计算量。在内存与部署方面，推理引擎会针对目标GPU自动搜索较优张量布局 and 底层执行策略，并在推理前预先分配固定大小的显存池，避免运行时动态分配带来的碎片化和额外开销。上述优化共同作用，使得VAE编解码在端侧GPU上的推理延迟显著低于常规动态图推理，同时保持重建质量基本不变。

3.8.2 物理层批处理优化

语义潜变量经过分段后，每段都会进入信道编码、调制、解调和译码流程。如果逐段独立处理，重复调度开销会被放大。本文将同一帧的多个分段组织为批量形式，使物理层能够一次处理多个码字。发送端批处理可抽象为

$$\mathbf{S} = \mathcal{G}_{\text{tx}}(\mathbf{B}), \quad (3.18)$$

接收端批处理可表示为

$$\hat{\mathbf{B}} = \mathcal{G}_{\text{rx}}(\mathbf{Y}, \sigma^2), \quad (3.19)$$

其中 $\mathbf{B}$ 表示批量信息比特， $\mathbf{S}$ 表示批量发送符号， $\mathbf{Y}$ 表示批量接收符号。批处理的意义很直接：让边缘GPU更充分地利用并行计算能力，减少小任务反复启动带来的时间浪费，并提升整体吞吐稳定性。

3.8.3 工程鲁棒性设计

端侧语义通信系统的工程风险不仅来自算法本身的性能边界，还广泛存在于多框架集成、模型部署和链路运行的细节之中。具体而言，模型目录缺失、TensorRT引擎与当前硬件不匹配、神经调制器未加载、导频长度与接收端配置不一致、Top-K索引解析失败等问题，均可能导致系统在运行时静默崩溃或产生不可复现的结果。此外，连续传输场景中的帧边界错位、传输中断后的状态恢复、重建频率波动以及设备资源竞争等，同样会破坏链路的稳定性。这些问题在离线实验阶段容易被忽视，但在系统演示和连续运行中会被显著放大。

针对上述风险，本文在系统设计中嵌入了多层级自检与回退机制。在模型加载阶段，检查是否包含必需的配置文件，TensorRT解码器会与深度学习框架PyTorch的参考输出比较平均绝对误差（Mean Absolute Error, MAE）以确认内部精度。MAE用于度量两个输出张量之间的平均差异，数值越小表示加速后端与参考后端越一致。神经调

制器在权重缺失时输出明确提示，接收端优先使用帧头中的运行时元信息（如导频长度、量化参数等）来动态配置解码流程。在链路层面，本文引入了帧级长度信息、重建间隔控制和异常回退路径，保证链路不中断，且状态可恢复。

3.9 本章小结

本章围绕已完成的端侧神经语义通信系统进行了设计说明。首先给出了系统总体架构，明确语义收发链路、神经物理层链路和真实复基带前端之间的关系；随后说明发送端如何完成VAE潜变量提取、Top-K选择、量化、LDPC编码和复数符号映射，接收端如何完成软解调、译码、反量化和语义重建。

进一步地，本章介绍了神经调制器、神经软解调器、可训练16QAM星座图、USRP接收前端和边缘端优化方法。整体来看，本文系统不是单独训练一个神经网络模型，而是把神经网络嵌入传统通信链路中的关键位置，并通过统一的数据边界保持可比较性和可替换性。下一章将基于本章设计，对端侧链路、神经物理层、可训练星座和USRP空口实验进行测试与分析。

第4章 实验与分析

4.1 引言

第三章围绕端侧语义通信链路给出了系统设计思路：发送端完成语义特征提取、信道编码与神经物理层映射，接收端完成同步、均衡、神经解调与语义重构。本章在此基础上开展实验验证，重点考察神经物理层替代方案在仿真信道中的可靠性、可训练星座在真实空口中的接收聚集效果，以及整条链路在Jetson边缘端运行时的时延水平与连续处理状态。

本章先介绍实验硬件、软件环境和评价指标，再分别给出仿真物理层对比、真实空口星座观测、边缘端时延统计和端到端图像语义通信可视化结果。实验内容从可控仿真逐步过渡到真实设备链路，既关注物理层误码和星座分布，也关注端侧运行代价和最终重建效果，从而形成对系统可靠性、可部署性和语义恢复能力的综合分析。

4.2 实验平台与评价指标

4.2.1 硬件实验平台

本文实验平台主要由Jetson Orin端侧计算设备和USRP X310软件无线电设备组成。Jetson Orin负责端侧语义处理、神经网络推理以及部分基带处理任务；USRP X310负责基带采样数据与真实射频信号之间的转换。两者结合后，可以同时观察算法可靠性、空口传输稳定性和端侧运行时延。



图 4.1 Jetson Orin端侧计算设备

图4.1展示了本文实验中使用的Jetson Orin端侧计算设备。该设备的优势在于集成

了面向边缘智能任务的GPU计算能力，能够在较小体积和功耗约束下完成语义特征提取、神经网络推理以及部分基带处理任务。对于本文系统而言，Jetson Orin承担端侧智能处理的核心节点作用，其运行状态会直接影响整条语义通信链路的实时性。




图 4.2 USRP X310与端侧语义通信系统实验平台

图4.2展示了USRP X310以及由Jetson Orin、软件无线电设备和射频收发链路构成的整体实验系统。实际测试时，Jetson Orin负责端侧语义处理和基带数据组织，USRP X310进一步完成数模转换、上变频、发射以及接收端的下变频处理。相比单纯仿真环境，真实系统会引入时钟偏差、射频非线性、功率漂移和环境噪声等因素；也正因为这些因素存在，空口实验才更能检验本文方案的工程可行性。

4.2.2 软件环境与实验工具

软件环境主要包括深度学习推理环境、物理层链路仿真环境和USRP设备驱动环境。深度学习部分用于完成语义特征提取、语义重构和神经物理层处理；物理层仿真部分用于构建AWGN信道、OFDM链路、传统QAM基线和可训练星座对比；USRP设备环境则用于完成真实空口发射、接收、同步、频偏补偿和信道均衡。

USRP环境部署的关键在于设备识别、采样率配置、射频中心频率设置以及收发缓冲稳定性。实际调试时，软件无线电链路并不会像理想仿真那样只由给定参数决定，它还会受到接口带宽、设备时钟、射频增益和缓存队列的共同影响。因此，本章把USRP的具体参数放在空口实验设置中展开说明，使平台配置与后续真实空口星座观测实验保持一致。

4.2.3 实验评价指标

本文实验评价指标围绕可靠性、星座分布、边缘端时延和端到端图像质量四类展开。可靠性指标主要包括误块率 (Block Error Rate, BLER) 与误比特率 (Bit Error Rate, BER)。BLER用于统计一个传输块是否整体出错, 更适合观察信道编码后的块级可靠性; BER用于统计逐比特错误比例, 更适合比较不同调制和解调方案的细粒度差异。星座分布主要观察接收星座点的聚集程度、类间可分性和噪声扩散趋势; 边缘端性能主要统计发送端、接收端各处理模块的平均时延; 端到端图像质量则结合峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR)、结构相似性 (Structural Similarity, SSIM) 以及可视化结果进行分析。上述指标分别对应物理层可靠传输、端侧运行效率和语义可辨识效果, 能够较完整地覆盖本文系统的关键性能。

设发送比特序列为 $\mathbf{b}$, 接收判决序列为 $\hat{\mathbf{b}}$, 则BER可表示为

$$\text{BER} = \frac{1}{N_b} \sum_{i=1}^{N_b} \mathbb{I}(b_i \neq \hat{b}_i), \quad (4.1)$$

其中, N_b 表示总比特数, $\mathbb{I}(\cdot)$ 为示性函数。若以传输块为统计单位, 设第 j 个数据块的发送比特向量为 $\mathbf{b}_j$, 接收判决向量为 $\hat{\mathbf{b}}_j$, 则BLER可写为

$$\text{BLER} = \frac{1}{N_{\text{blk}}} \sum_{j=1}^{N_{\text{blk}}} \mathbb{I}(\mathbf{b}_j \neq \hat{\mathbf{b}}_j). \quad (4.2)$$

对于端到端图像语义通信, 图像重构质量可以从像素误差、结构保持和感知一致性三个角度描述。设原始图像为 $\mathbf{x}$, 重构图像为 $\hat{\mathbf{x}}$, 像素最大取值为 L , 均方误差为

$$\text{MSE} = \frac{1}{HWC} \sum_{h=1}^H \sum_{w=1}^W \sum_{c=1}^C (x_{h,w,c} - \hat{x}_{h,w,c})^2, \quad (4.3)$$

则PSNR定义为

$$\text{PSNR} = 10 \log_{10} \frac{L^2}{\text{MSE}}. \quad (4.4)$$

PSNR越高, 说明重构图像与原图在像素误差意义上越接近; 但它主要关注逐像素差异, 对结构和感知质量的刻画有限。

SSIM从亮度、对比度和结构相关性角度评价两幅图像的相似程度^[46], 其形式为

$$\text{SSIM}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}. \quad (4.5)$$

其中, μ_x 和 $\mu_{\hat{x}}$ 表示图像均值, σ_x^2 和 $\sigma_{\hat{x}}^2$ 表示方差, $\sigma_{x\hat{x}}$ 表示协方差, C_1 和 C_2 为稳定常数。由于语义通信并不以逐像素复原为唯一目标, 本文在分析端到端图像结果时, 将PSNR、SSIM对应的评价含义与可视化结果结合起来理解, 既观察像素误差和结构相似程度,

也关注主体是否可辨认、场景结构是否连续、主要颜色与轮廓是否保持。

4.3 仿真环境下的物理层消融实验

4.3.1 神经物理层替换方案的分阶段对比实验

仿真信道下的第一组实验面向神经物理层替代方案的可靠性比较。在保持信道编码和译码流程基本一致的条件下，实验逐步替换符号映射、软信息恢复和软信息校正环节，并通过对比实验分析不同模块对块错误率（Block Error Rate, BLER）的影响。图4.3和图4.4保留两组具有代表性的结果：前者展示不同物理层组合的整体BLER变化，后者展示在可训练星座与神经解调组合基础上进一步进行软信息校正后的结果，以验证各模块的有效性。

从图4.3可以看出，单独替换某一个物理层环节时，性能提升并不是无条件成立的。传统QAM与APP解调构成了较稳定的参考基线；若仅在接收端引入神经解调，模型面对的仍然是规则QAM星座，其判决边界虽然具备学习能力，但与发送端符号分布之间缺少协同约束，因此在部分信噪比区间内优势并不明显。相比之下，可训练星座的加入改变了发送端符号点的位置分布，使调制映射不再完全受规则网格限制，这为接收端判决提供了更大的调整空间。由此可以看出，该方案的价值不只是改变接收端判决方式，还在于让发送端星座几何结构能够围绕传输目标进行适度调整，从而有效提升链路的抗噪性能。




图 4.3 仿真信道下不同物理层替换组合的BLER对比

图4.4进一步说明了软信息校正环节的作用。可训练星座与神经解调组合已经能够形成较好的端到端匹配，但软信息在进入译码环节前仍可能存在置信度偏移：有些符号被判得过于自信，有些符号又显得保守。经过校正后，译码器接收到的软信息分

布更平滑，BLER曲线在中高信噪比区间表现出更明显的下降趋势。这一现象与第二章关于神经物理层需要同时学习判决结果和可靠度表达的分析相呼应。




图 4.4 可训练星座与神经解调联合优化后的BLER对比

表4.1给出了基于神经网络的调制与软解调方案和传统物理层方案在不同批处理规模下的吞吐量和平均处理时延。批处理规模为1时，两种方案都存在较大的单次调度开销，神经方案的吞吐量为39.6 codewords/s，高于传统方案的35.5 codewords/s，单码字时延也由1126.9 ms降至980.3 ms。随着批处理规模增大，吞吐量显著提升；当批处理规模增加到128时，传统方案和神经方案分别达到1417.0 codewords/s与1538.4 codewords/s。这个结果说明，基于神经网络的调制与软解调并不一定意味着更高时延，在并行度足够时，其矩阵化计算反而能够更好地利用边缘端并行计算资源。

表 4.1 基于神经网络的调制与软解调和传统物理层时延吞吐记录表

批处理规模	传统方案吞吐量 /(codewords/s)	神经方案吞吐量 /(codewords/s)	传统方案时延 /(ms/codeword)	神经方案时延 /(ms/codeword)
1	35.5	39.6	1126.9	980.3
8	225.3	246.2	139.3	118.6
32	619.8	720.1	21.6	22.1
128	1417.0	1538.4	9.1	9.8

批处理规模为32和128时，神经方案的单码字时延分别为22.1 ms和9.8 ms，略高于传统方案的21.6 ms和9.1 ms。原因在于吞吐量反映的是单位时间内处理的总体数量，而单码字时延还受到批内等待、内存访问和数据组织方式影响。神经方案在大批量下具有更高的总体处理能力，但单个样本的等待时间仍需结合实时性需求综合判断。因此，端侧运行中需要在吞吐量与时延之间进行权衡，根据实时性需求选择合适批处理

规模，而不是简单追求最大吞吐。

4.3.2 可训练星座图仿真对比实验

可训练星座实验进一步聚焦发送端符号点本身。图4.5和图4.6给出了标准16-QAM与训练后星座的坐标分布对比。标准16-QAM的优势在于其结构规则、判决边界清晰且天然适合解析处理；可训练星座则在保持16个符号点数量不变的前提下，对部分点位进行了非均匀调整。这里不宜简单认为星座越不规则越好，更准确的理解是：训练过程在给定信道和接收规则下，围绕降低误码风险重新分配了符号间距离、平均功率和局部判决边界之间的关系。




图 4.5 标准16-QAM星座坐标分布




图 4.6 可训练星座坐标分布

为验证该星座图的性能,本文将标准16-QAM与可训练星座分别嵌入同一套OFDM仿真链路中进行对比。该链路包含数据子载波映射、导频插入、循环前缀、加性高斯白噪声、接收端快速傅里叶变换、导频辅助信道估计与判决恢复等环节,因此与真实空口实验基带处理流程具有较强对应关系。图4.7给出了不同SNR下的BER变化趋势。

表 4.2 标准16-QAM与可训练星座在不同SNR下的BER对比

SNR/dB	标准16-QAM BER	可训练星座BER
-10	$4.155\ 640 \times 10^{-1}$	$4.154\ 125 \times 10^{-1}$
0	$2.271\ 886 \times 10^{-1}$	$2.256\ 145 \times 10^{-1}$
4	$1.325\ 589 \times 10^{-1}$	$1.319\ 360 \times 10^{-1}$
8	$5.230\ 640 \times 10^{-2}$	$5.192\ 761 \times 10^{-2}$
16	$1.178\ 451 \times 10^{-4}$	$7.575\ 758 \times 10^{-5}$

从表4.2可以更清楚地看到两类星座的差异。低SNR区间内,噪声占主导,标准16-QAM与可训练星座的BER整体上接近,例如,在-10 dB时二者分别为 $4.155\ 640 \times 10^{-1}$ 和 $4.154\ 125 \times 10^{-1}$,差距很小;在0 dB和4 dB时,可训练星座仍然只体现出轻微优势。

这说明在强噪声条件下,星座点位置的局部优化很难完全抵消噪声扩散,系统可靠性主要仍由信道条件决定。不过,从完整数据趋势看,可训练星座在所有观测SNR下均保持了不高于标准16-QAM的BER,这一点并不应被忽略。它说明训练过程没有破坏星座图的基本可判决性,反而在相同OFDM链路中形成了稳定的小幅收益。




图 4.7 仿真环境下标准16-QAM与可训练星座的BER对比

当SNR提升后,可训练星座的优势开始变得更明显。8 dB时,BER从标准16-QAM的 5.230640×10^{-2} 降至 5.192761×10^{-2} ; 16 dB时, BER从 1.178451×10^{-4} 进一步降至 7.575758×10^{-5} , 相对下降幅度约为35.71%。这个改善幅度已经比较可观,因为在较低误码率区间继续下降并不容易。可以这样理解:当噪声不再完全淹没符号结构后,训练得到的非均匀点位分布开始更充分地转化为判决收益。星座训练在中高信噪比区间改善了符号间的有效判决间隔,而不只是改变图形外观。该结果与真实空口下更清晰的接收聚类现象相互呼应,说明可训练星座在仿真链路和实际链路中具有一致的优化方向。

4.4 真实空口下的物理层系统验证实验

4.4.1 空口实验设置

仿真环境虽然可控,但无法覆盖真实设备中的收发时钟偏差、射频非线性、功率漂移以及环境噪声。为此,本文将前述物理层替换方案接入USRP X310平台进行空口验证。该实验重点观察经过真实射频链路后,替换后的物理层符号是否仍能在接收端形成可判决的星座聚类。

空口链路采用OFDM体制,快速傅里叶变换点数为256,循环前缀(Cyclic Prefix, CP)长度为16。CP是在OFDM符号前复制的一段尾部采样,用于降低多径传播造成

的符号间干扰。导频采用梳状插入方式，并保留直流和边缘保护子载波；同步部分使用Zadoff-Chu序列进行帧定位，接收端进一步完成频偏补偿和信道均衡。Zadoff-Chu序列具有良好的自相关特性，适合用于接收端寻找帧起始位置。成形滤波采用根升余弦（Root Raised Cosine, RRC）滤波，过采样倍数为4，滤波跨度为10，滚降系数为0.5。RRC滤波用于限制信号带宽并减小符号间干扰，是真实发射链路中常见的脉冲成形方法。采样率设置为5 MHz，符号率约为1.25 MHz，射频中心频率位于3.5 GHz附近。实验中将功率放大器（Power Amplifier, PA）增益作为主要调节变量，分别观察增益为0、10和25时的接收星座分布。PA增益用于调节发射链路的输出功率，它不等同于严格的SNR，但能够反映不同发射功率工作点下的接收效果变化。

表 4.3 真实空口实验主要参数

参数类别	参数设置
射频设备	USRP X310软件无线电平台
端侧处理设备	Jetson Orin
基带体制	OFDM, FFT点数256, 循环前缀长度16
导频与保护子载波	梳状导频, 保留直流与边缘保护子载波
同步方式	Zadoff-Chu序列辅助帧同步与频偏补偿
成形滤波	根升余弦滤波, 过采样倍数4, 跨度10, 滚降系数0.5
采样率与中心频率	采样率5 MHz, 射频中心频率位于3.5 GHz附近
对比方案	标准QAM星座与可训练星座
主要变量	PA增益档位: 0、10、25
观测指标	接收星座聚集程度、类间可分性和散点扩散趋势

4.4.2 真实空口下替换物理层的接收星座观测

图4.8给出了三个增益档位下，标准QAM与本文可训练星座方案经过真实空口传输、同步、频偏补偿和信道均衡后的接收星座图。本节展示的是物理层进入USRP链路后的接收端观测结果，重点在于说明训练得到的星座映射能够接入真实射频收发流程，并在不同发射增益条件下保持可解释的聚类结构。

图4.8重点反映替换后的物理层方案在真实射频链路中能否保持可判决结构。PA增益为0时，传统QAM的散点扩散比较明显，部分符号簇之间已经出现粘连，接收端很难仅凭视觉轮廓判断稳定的判决边界；相比之下，可训练星座虽然同样受到噪声和设备链路波动影响，但仍然能够看出较清楚的聚类雏形。低增益条件下接收信号本身偏弱，若星座结构在此时还能保留轮廓，说明训练得到的点位分布并没有只适配理想仿真信道，而是对真实空口扰动具有一定容忍度。




图 4.8 真实空口下不同PA增益档位的接收星座图对比

当PA增益提高到10和25后，两类方案的接收星座都会变得更集中，但可训练星座的改善更加直观。传统QAM在增益升高后能够恢复出更明显的网格结构，这是功率提升带来的正常收益；可训练星座则进一步表现出更紧凑的散点簇和更清楚的类间间隔，尤其在中高增益条件下，接收散点围绕目标位置展开得更集中，边缘点对相邻簇的侵入更少。换句话说，传统方案更多依赖链路增益改善散点扩散状态，可训练星座则在点位设计阶段为接收端预留了更合适的判决空间。因此，图4.8不仅说明该方案能够接入USRP空口链路，也说明其在真实射频影响下仍能体现出比标准星座更好的聚类稳定性。

PA增益并不等同于严格意义上的SNR，它更像是调节链路工作点的实验变量。在真实空口观测中，可训练星座保持了更清晰的接收聚类 and 更稳定的类间可分性，并为端到端语义传输提供了更有利的物理层输入条件。结果说明，训练得到的星座几何并没有停留在仿真链路中，而是能够在USRP收发环境中体现出可观察的接收优势。




图 4.9 真实空口下不同PA增益档位的频率域功率分布对比

图4.9从频率域功率分布角度补充了真实空口链路的观测结果。星座图反映的是接收端判决空间的分布，频率域功率分布则能从另一个角度观察信号经过真实射频链

路后是否稳定、是否存在异常扩散或明显畸变。两类图结合起来看，结论会更稳：可训练星座不仅在接收星座图上表现出更清晰的聚类轮廓，在频率域功率分布上也能够随PA增益变化呈现出可解释、可重复的变化趋势。

具体来看，PA增益从0提升到10和25后，传统QAM与可训练星座的功率水平都会随之抬升，说明链路增益调节能够有效作用于实际发射过程。更值得关注的是，可训练星座在不同增益档位下没有出现明显异常塌缩、突发尖峰或不可解释的频域畸变，功率分布与接收星座聚类之间具有较好对应关系。前文星座图中观察到的聚类改善，也得到了频率域功率分布的进一步印证。

4.5 边缘端性能与时延实验分析

4.5.1 边缘端推理时延统计方法

端侧语义通信不能只看传输效果，还要看它能不能在设备上连续跑起来。Jetson Orin这类边缘平台资源有限，语义编码、物理层映射、接收端神经解调和语义重构都会占用算力和显存。如果每个模块都只追求单独的模型表现，不管推理时延，系统也许能完成演示，却很难支撑实时传输。

本文把端到端链路拆成四个计时对象：发送端（Transmitter, TX）语义特征提取、发送端信道编码与基带映射、接收端（Receiver, RX）均衡与神经网络解调、接收端语义特征重构。TX对应语义比特和发射符号生成一侧，RX对应接收、解调和语义重建一侧。每个模块都重复统计多次，再取平均耗时；同一模块分别记录优化前和优化后结果。优化前对应常规动态图执行，优化后对应图编译和推理加速后的端侧执行。这组对比属于工程优化消融，用来判断同一套系统经过边缘端推理优化后能压下多少时延。

4.5.2 各模块时延优化结果

性能提升比例按式4.6计算：

$$\eta = \frac{T_{\text{before}} - T_{\text{after}}}{T_{\text{before}}} \times 100\%, \quad (4.6)$$

其中， T_{before} 表示优化前平均耗时， T_{after} 表示优化后平均耗时。该指标用于衡量同一处理模块在端侧优化前后的相对时延变化，便于比较不同模块的加速收益。

表4.4和图4.10共同给出了边缘端时延优化结果。表格提供各模块的具体耗时与提升比例，柱状图则更直观地展示优化前后差异；由于不同模块的时延跨度较大，图中采用对数坐标以避免低时延模块被压缩到难以辨认。由表可知，端到端总时延从3464.9 ms降至639.8 ms，整体下降81.54%，显著提升了系统的实时传输效率。从图中也可以看到，优化后的柱形整体低于常规执行方式，且下降并非集中在单一模块，说明优化

策略对完整处理链路均具有较好的加速效果。

表 4.4 Jetson Orin边缘端各模块推理时延优化对比

处理模块	常规执行耗时/ms	推理优化后耗时/ms	性能提升比例
TX端：VAE语义特征提取	798.1	258.2	67.65%
TX端：LDPC编码与调制	88.3	7.4	91.62%
RX端：LDPC解码与解调	1380.9	110.0	92.03%
RX端：VAE语义特征重构	1197.6	264.2	77.94%
端到端总时延	3464.9	639.8	81.54%




图 4.10 边缘端各模块推理时延优化对比

分模块看,TX端LDPC编码与基带映射由88.3 ms降至7.4 ms,提升比例达到91.62%;RX端LDPC译码与神经解调由1380.9 ms降至110.0 ms,提升比例为92.03%。这两个环节收益最明显,说明图编译和并行执行对规则张量运算特别有效。VAE相关模块优化幅度略低一些,但仍然很关键:TX端语义特征提取由798.1 ms降至258.2 ms,RX端语义特征重构由1197.6 ms降至264.2 ms,分别降低67.65%和77.94%。这类模块包含较多图像特征变换和中间张量搬移,除了计算本身,还会受到显存访问和数据格式转换影响,因此提升比例低于基带处理部分是合理的。

从系统角度看,优化前端到端总时延为3464.9 ms,连续帧处理时会出现较明显等待;优化后总时延下降到639.8 ms,链路响应节奏明显变快。这个结果说明,端侧系统除了算法可行,还必须经得起边缘设备上的实际运行压力。表图相邻呈现后可以更清楚地看到,本文用边缘GPU优化把神经网络模块和物理层处理压缩到较稳定的时延

范围内，为端侧部署提供了直接工程支撑。

4.6 端到端图像语义通信重构质量分析

完成物理层验证和边缘端时延分析后，还需要回到本文最核心的任务：图像语义信息能否经过Jetson端侧处理、真实空口传输和接收端语义重构后，形成可辨认、可理解的视觉结果。真实空口下的端到端语义图像传输同时受到图像内容、端侧推理状态、射频链路波动和重构模型表达能力的共同影响，因此本文采用PSNR、SSIM和原图与重构图并列展示的方式分析系统输出，使读者能够同时观察量化质量和接收端恢复出的视觉内容。

表4.5给出了多组真实空口重构图像的质量统计结果。PSNR越高表示逐像素误差越小，SSIM越高表示图像结构相似性越强。由表可知，测试样本的平均PSNR达到28.10 dB，平均SSIM达到0.982；中位数分别为28.13 dB和0.985，与平均值较为接近，说明多数样本的重构质量比较稳定。即使在统计中的最差样本上，PSNR仍为24.22 dB，SSIM仍保持在0.940，表明真实空口链路下的重构结果没有出现明显结构崩塌，主体内容和整体布局仍具有较好的保留程度。

最优样本的PSNR为30.80 dB，SSIM为0.994，说明在链路状态较稳定、图像内容与语义模型匹配较好的情况下，系统能够获得较高的像素一致性和结构一致性。平均值与最优值之间仍存在一定差距，这也符合真实空口实验的特点：射频链路会受到短时功率波动、相位扰动和接收端前端校正误差影响，不同帧之间难免存在质量起伏。不过，从平均值、中位数和最差值共同来看，本文系统在多组样本上保持了较高的结构相似性，这比单独展示一两张效果较好的图像更能说明链路的稳定性。

表 4.5 真实空口下端到端图像重构质量统计

统计项	PSNR/dB	SSIM
平均值	28.10	0.982
中位数	28.13	0.985
最优值	30.80	0.994
最差值	24.22	0.940

图4.11给出了两组真实空口条件下的端到端图像语义通信可视化结果。每组结果由原始输入图像和接收端重构图像构成，前者表示发送端采集到的视觉内容，后者表示经过语义特征提取、物理层传输、无线空口接收以及语义解码后恢复出的图像。该实验将第三章设计的语义处理链路、神经物理层和边缘端部署流程连接为完整闭环，用于观察接收侧对原始画面主体结构和场景内容的恢复情况。

从图4.11可以看出，接收端重构图像更偏向于保持主体轮廓、区域结构和主要视觉语义，而非对原始图像进行逐像素复制。这一点符合本文系统设计的出发点。发送端并未把完整像素矩阵直接作为传输目标，而是先对图像进行语义特征压缩，再通过信道编码与物理层映射完成传输；因此，接收端恢复出的图像在局部纹理、边缘锐度和细小颜色过渡上可能出现一定损失，但只要主体结构仍然稳定，就说明语义链路已经发挥作用。




图 4.11 真实空口下端到端图像语义通信可视化结果

更值得注意的是，图中重构结果来自真实空口链路，而不是完全可控的仿真信道。真实设备会引入频偏、相位扰动、射频非线性和环境噪声，这些因素都会使接收端特征恢复变得更难。在这样的条件下，重构图像仍能保留主要画面内容，表4.5中的平均SSIM达到0.982，说明前文所验证的可训练星座、接收端处理流程和边缘端语义重构模块能够组合成一条可运行的端到端系统链路。PSNR和SSIM给出了多组样本上的量化支撑，图像对比则展示真实接收结果的直观形态，二者共同说明本文系统在真实空口环境下能够完成较稳定的图像语义恢复。

重构图像中仍能看到一定细节退化，例如局部纹理变平滑、边缘略微模糊、色彩层次减少等。这与语义压缩中的信息取舍和空口传输误差有关。对端侧语义通信系统

而言,这种取舍具有工程合理性:系统牺牲一部分像素级细节,换来更紧凑的语义表示、更低的传输负担,以及可在Jetson边缘端部署的整体流程。结合第4.5节时延结果可以看出,本文系统不仅能够完成真实空口下的图像重构,也具备一定端侧实时运行基础。

表4.5和图4.11分别从定量结果和可视化结果两个角度给出了端到端实验的支撑。可以看到,基于神经网络的端侧语义通信系统能够将图像语义信息送入真实空口链路,并在接收端恢复出具有可辨识内容的重构图像。若结合前文的接收星座观测和边缘端时延结果来看,本文系统不仅完成了物理层替换模块的有效性验证,也进一步说明该链路具备在端侧设备上闭环运行的工程可行性。

4.7 本章小结

本章围绕端侧语义通信系统进行了实验验证和结果分析。实验平台由Jetson Orin边缘计算设备和USRP X310软件无线电设备构成,既用于验证神经网络物理层在仿真信道中的可靠性,也用于观察真实空口条件下的星座聚类、频域功率分布和端侧运行时延。评价指标包括BER、BLER、接收星座分布、模块时延、PSNR、SSIM和端到端可视化结果,从传输可靠性、工程部署和语义重构三个角度支撑系统分析。

仿真环境下,本文对神经物理层替换方案进行了分阶段比较。实验结果表明,神经解调、可训练星座以及软信息校正等模块能够改善发送端映射与接收端判决之间的匹配关系;其中,可训练星座在中高信噪比区间表现出更低的BER,并与真实空口观测结果形成对应。真实空口实验进一步表明,在PA增益为0、10和25的不同工作点下,可训练星座相比标准QAM具有更清晰的接收聚类和更稳定的类间可分性,频率域功率分布也与星座观测结果相互印证。

边缘端性能实验中,图编译与推理加速将系统端到端总时延由3464.9 ms降至639.8 ms,整体下降81.54%。发送端基带映射、接收端解调译码和语义重构等环节均获得明显收益,说明本文系统不仅能够完成算法层面的链路验证,也具备在Jetson边缘设备上运行的工程基础。两组真实空口下的原始图像与重构图像对比展示了完整语义通信链路的闭环效果,说明本文系统已经实现从图像语义特征提取、无线传输到接收端图像重构的端到端验证。

第5章 总结与展望

5.1 全文工作总结

本文围绕端侧图像语义通信系统的设计与实现，完成了从理论分析、系统设计到实验验证的整体工作。全文主线可以概括为：以图像语义传输为应用场景，在传统无线通信链路基础上引入VAE潜变量表示、神经物理层替代、可训练星座图、真实空口验证和边缘端推理优化，构建一条面向端侧设备运行的神经语义通信链路。与只关注单个模型性能的研究不同，本文更强调系统闭环：图像能否被压缩为语义表示，语义比特能否通过物理层可靠传输，接收端能否重建可辨识图像，整条链路又能否在Jetson Orin边缘设备上以较低时延运行。

第一章从研究背景出发，说明传统比特通信在图像、视频和智能感知任务中面临的新需求，并引出语义通信、神经物理层和端侧AI部署三条研究线索。该章指出，未来通信系统不应只追求比特级完全一致，还需要关注语义有效性、任务可用性和资源效率。对于本文所研究的图像语义通信而言，接收端是否能够恢复主体结构、场景轮廓和主要视觉内容，是评价系统价值的重要依据。

第二章围绕相关技术与理论基础展开分析。该章从语义通信的基本思想和图像潜变量表示谈起，说明VAE潜变量可以作为图像语义信息进入物理层之前的中间载体；可靠物理层部分分析LDPC编码、QAM软解调、OFDM导频估计，明确传统通信理论在本文系统中的支撑作用；神经物理层部分讨论神经调制、神经软解调和可训练星座图的理论依据，说明神经网络适合增强非线性映射和软信息恢复环节；边缘计算、端侧推理加速和软件无线电相关内容则用于分析系统落地条件。这些内容为后续系统模块划分、物理层替代策略和真实空口实验设计奠定了理论基础。

第三章给出了本文端侧神经语义通信系统的具体设计。发送端把图像归一化后送入VAE编码器，得到可选择、可量化的潜变量表示；再经过Top-K选择、分位数量化、LDPC编码和复数符号映射形成可传输序列。接收端按照相反流程完成帧解析、软解调、LDPC译码、反量化、潜变量回填和VAE语义重建。物理层部分采用渐进式替代思想：保留传统编码和标准链路接口，重点设计神经调制器、神经软解调器和可训练16QAM星座图，使系统能够在传统方案和神经方案之间进行可控对比。真实链路部分引入USRP接收前端，通过导频同步、信道估计、均衡和残差补偿改善接收符号几何状态。端侧部分围绕TensorRT推理加速、物理层批处理和运行鲁棒性进行设计，为第四章实验提供系统基础。

第四章对上述系统进行了实验验证与结果分析。实验平台由Jetson Orin端侧计算

设备和USRP X310软件无线电设备构成,评价内容覆盖仿真物理层对比、可训练星座仿真、真实空口星座观测、频域功率分布、边缘端时延以及PSNR、SSIM和端到端图像语义通信可视化结果。仿真环境下,神经物理层替换方案通过分阶段实验展示神经解调、可训练星座和软信息校正对可靠性的影响;可训练星座在中高SNR区间表现出更低BER,并在16 dB时取得更明显的误码率下降。真实空口实验表明,在PA增益为0、10和25的不同工作点下,可训练星座相比标准QAM具有更清晰的接收聚类 and 更稳定的类间可分性,频率域功率分布也与星座观测结果相互印证。边缘端性能实验中,推理优化把系统端到端总时延由3464.9 ms降低至639.8 ms,整体下降81.54%,说明本文系统不仅具有算法可行性,也具备较明确的端侧部署价值。两组真实空口下的原图与重构图像对比展示了完整语义通信链路的闭环效果。

5.2 主要工作特点

本文工作的第一个特点是把语义通信问题放在端侧系统中讨论。语义通信并不只是把图像压缩得更小,也不只是用神经网络生成一张视觉上相似的图像。真正进入系统后,它必须与信道编码、调制映射、接收软信息、真实链路扰动和端侧推理时延共同工作。本文围绕这一点构建了从图像输入到接收端重构图像的完整链路,使语义通信从概念层面的语义传递落到可执行的收发流程中。

第二个特点是采用渐进式神经物理层替代路线。本文没有简单地把全部传统物理层模块替换为神经网络,而是在保留LDPC编码、OFDM链路和导频估计等成熟环节的基础上,重点替换调制映射、软解调和星座几何结构。这样做有两个好处:一方面,系统保留了传统通信链路的稳定性和可解释性;另一方面,神经网络可以集中作用于传统解析模型不易完全覆盖的非线性映射和软信息恢复环节。第四章的分阶段实验也说明,这种替代方式更便于分析不同模块对性能变化的贡献。

第三个特点体现在可训练星座图上。它可以看成神经物理层的一种可解释参数化形式:星座点直接落在复平面,调整的是点位坐标,而不是一个完全黑箱的调制器。这样既保留比特标签到星座点的传统接口,也给训练目标留下调整空间,后续分析和部署都更直观。仿真中,可训练星座在中高SNR区间降低BER;真实空口下,即便PA增益较低,接收星座仍能看出聚类轮廓,增益提高后类间分离更稳定。也就是说,它带来的变化不止是图上点位不同,真实链路观测里也能看到物理层收益。

第四个特点落在端侧运行效率。端侧语义通信不仅要打通传输闭环,还要在边缘设备上连续运行。本文统计Jetson Orin上的发送端语义特征提取、LDPC编码与调制、接收端解调译码、VAE语义重构等模块时延。推理优化后,端到端总时延从3464.9ms降至639.8 ms。这个结果说明,图编译、推理后端优化和批处理确实改善了系统运行状

态。对端侧AI通信而言，瓶颈常常不只来自算法精度，计算调度、显存访问和连续帧处理开销同样会限制系统表现。

第五个特点是通过真实空口和可视化结果增强系统可信度。仿真环境能够提供可控比较，但真实射频链路会引入频偏、相位旋转、功率漂移和环境噪声。本文在USRPX310平台上观察标准QAM与可训练星座的接收星座和频域功率分布，并进一步展示真实空口下的原图与重构图像对比。由此形成了从物理层接收质量、端侧运行时延到语义重建效果的验证链条。

5.3 不足与改进方向

本文已经完成端侧神经语义通信系统的设计和验证，不过从更长期的工程应用看，仍有几个问题值得继续优化。

第一，图像语义质量评价还可以更细。第四章使用PSNR和SSIM，并结合原图与真实空口重构图像做可视化对比，能够说明系统闭环是否跑通、主体结构是否保留。面向智能感知任务时，评价还应加入目标识别准确率、关键区域保持率或语义一致性评分，把视觉可辨认进一步推进到任务可用。

第二，神经软解调和真实空口适应性仍有提升空间。神经解调器要判断比特取值，还要给LDPC译码器提供合适的置信度；真实空口又会叠加频偏、相位旋转、非线性失真和环境变化。后续可围绕多SNR联合训练、软信息温度校准、译码反馈约束，以及不同距离和遮挡条件下的连续测试做更细的验证，让神经物理层输出更稳定地服务于信道译码和语义重构。

第三，端侧系统还需要流水线级优化，并把语义压缩和物理层保护放在一起考虑。当前优化已经明显降低端到端时延，但语义编码、物理层处理、无线收发、语义重建和图像保存之间仍有串行等待。后续可研究异步流水线、缓存复用和硬件感知调度，再依据潜变量重要性动态分配信道编码冗余、调制阶数或重传策略，让关键语义分量获得更强保护，同时压低连续帧传输的平均等待时间。

5.4 未来研究展望

未来工作可以从语义层、物理层和端侧部署三个方向继续推进。

在语义层方面，可以研究更加稳定的图像语义表示和任务驱动评价。当前系统以VAE潜变量作为语义载体，能够完成图像重建闭环。若面向实际智能感知任务，还可以进一步结合目标检测、场景分类或多模态理解模型，使通信链路不只恢复图像，还能直接服务于后续决策。这会使语义通信从图像可视化恢复进一步转向任务层应用场景。

在物理层方面,可以进一步研究自适应神经调制与可训练星座。不同信道条件下,合适的星座几何、导频密度和软信息尺度并不完全相同。未来可以根据实时信道状态调整星座点分布或解调器输出尺度,使系统在低SNR、功率波动和硬件非理想条件下保持更稳定的误码性能。

在真实空口方面,可以推进更长时间、更复杂环境下的端到端语义传输。本文已经完成USRP平台下的接收星座观测、频域功率分析和图像重构展示。下一步可以加入移动场景、多径反射环境和多组图像内容测试,观察系统在更接近实际应用条件下的稳定性。

在端侧部署方面,可以继续优化轻量化推理和流水线调度。端侧系统的目标不是盲目压缩模型,而是在重建质量、误码性能、推理时延和功耗之间取得平衡。未来可结合低精度推理、模型剪枝、异步缓存和硬件感知调度,使语义编码、物理层处理和语义重建之间形成更平滑的运行节奏。

本文完成了面向端侧部署的图像语义通信系统设计与实验验证。实验结果说明,传统通信理论提供的稳定接口和神经网络带来的自适应能力可以放在同一条链路里协同工作。神经网络没有必要替代全部传统模块,但适合用在语义表示、调制映射、软信息恢复、星座优化和端侧推理加速等关键环节。沿着这一思路继续推进,语义通信更有机会从仿真研究走向真实边缘设备和实际无线链路。

参考文献

- [1] Shannon C E. A mathematical theory of communication[J]. Bell System Technical Journal, 1948, 27(3): 379-423.
- [2] Shannon C E, Weaver W. The mathematical theory of communication[M]. Urbana: University of Illinois Press, 1949.
- [3] Cover T M, Thomas J A. Elements of information theory[M]. 2nd ed. Hoboken: Wiley, 2006.
- [4] Zhang P, Niu K, Yao S, et al. Semantic communications for future: Basic principles and implementation methods[J]. Journal on Communications, 2023, 44(5): 1-14.
- [5] Bourtsoulatz E, Kurka D B, Gündüz D. Deep joint source-channel coding for wireless image transmission[J]. IEEE Transactions on Cognitive Communications and Networking, 2019, 5(3): 567-579.
- [6] Kurka D B, Gündüz D. Deepjscc-f: Deep joint source-channel coding of images with feedback[J]. IEEE Journal on Selected Areas in Information Theory, 2020, 1(1): 178-193.
- [7] Xie H, Qin Z, Li G Y, et al. Deep learning enabled semantic communication systems[J]. IEEE Transactions on Signal Processing, 2021, 69: 2663-2675.
- [8] Hu L, Yu L, Qin Z. Deep learning-based semantic communication system for wireless image transmission[J]. IEEE Wireless Communications Letters, 2025, 14(8): 2391-2395.
- [9] Lokumarambage M, Sivalingam T, Dong F, et al. Generative ai-based vector quantized end-to-end semantic communication system for wireless image transmission[J]. IEEE Transactions on Machine Learning in Communications and Networking, 2025, 3: 1050-1074.
- [10] O'Shea T J, Hoydis J. An introduction to deep learning for the physical layer[J]. IEEE Transactions on Cognitive Communications and Networking, 2017, 3(4): 563-575.
- [11] Dörner S, Cammerer S, Hoydis J, et al. Deep learning based communication over the air[J]. IEEE Journal of Selected Topics in Signal Processing, 2018, 12(1): 132-143.
- [12] Gündüz D, de Kerret P, Sidiropoulos N D, et al. Machine learning in the air[J]. IEEE Journal on Selected Areas in Communications, 2019, 37(10): 2184-2199.
- [13] Honkala M, Korpi D, Huttunen J M J. Deeprrx: Fully convolutional deep learning receiver[J]. IEEE Transactions on Wireless Communications, 2021, 20(6): 3925-3940.
- [14] Cammerer S, Ait Aoudia F, Hoydis J, et al. A neural receiver for 5g nr multi-user mimo[C]//IEEE Globecom Workshops. 2023: 329-334.
- [15] Shi W, Cao J, Zhang Q, et al. Edge computing: Vision and challenges[J]. IEEE Internet of Things Journal, 2016, 3(5): 637-646.
- [16] Chen J, Ran X. Deep learning with edge computing: A review[J]. Proceedings of the IEEE, 2019, 107(8): 1655-1674.
- [17] Saadat H, Albaseer A, Abdallah M M, et al. Semcom-optima: Empirically-driven optimization of semantic image transmission across heterogeneous edge-cloud systems[J]. IEEE Open Journal of the Computer Society, 2026, 7: 93-104.

- [18] Liu X, Zeng Q, Lu L, et al. Review on the application of semantic communication in edge computing networks[J]. *Application Research of Computers*, 2025, 42(7): 1930-1938.
- [19] Strinati E C, Barbarossa S. 6g networks: Beyond shannon towards semantic and goal-oriented communications[J]. *Computer Networks*, 2021, 190: 107930.
- [20] Lan Q, Zhang Z, Wen D, et al. What is semantic communication? a view on conveying meaning in the era of machine intelligence[J]. *Journal of Communications and Information Networks*, 2021, 6(4): 336-371.
- [21] Nguyen L X, Raha A D, Aung P S, et al. A contemporary survey on semantic communications: Theory of mind, generative ai, and deep joint source-channel coding[J]. *IEEE Communications Surveys & Tutorials*, 2026, 28: 2377-2417.
- [22] Sharif S, Khandaker F, Naeem M, et al. Resource optimization for semantic communication in 6g networks: A survey[J]. *IEEE Open Journal of the Communications Society*, 2026, 7: 1602-1642.
- [23] Zhang P, Niu K, Tian H, et al. 6g mobile communication technology prospect[J]. *Journal on Communications*, 2019, 40(1): 141-148.
- [24] Qin Z, Zhao T, Li F, et al. A survey of multimodal semantic communication[J]. *Journal on Communications*, 2023, 44(5): 28-41.
- [25] Wang X, Jia H, Cheng N, et al. Latent diffusion model based denoising receiver for 6g semantic communication: From stochastic differential theory to application[R]. *arXiv:2506.05710*, 2025.
- [26] Chen S, Wu T, Chen Z, et al. Text-guided diffusion model-based generative communication for wireless image transmission[R]. *arXiv:2510.21299*, 2025.
- [27] Lokumarambage M, Sivalingam T, Dong F, et al. Latent prediction-based generative semantic communication for video transmission in wireless networks[J]. *IEEE Open Journal of the Communications Society*, 2026, 7: 3974-3986.
- [28] Luo P, Liu Y, Zhang C, et al. Semantic communication system with efficient fusion of global and local context features[J]. *Journal on Communications*, 2023, 44(7): 14-25.
- [29] Park T, Hong E, Jeon Y S, et al. Robust deep joint source channel coding for task-oriented semantic communications[R]. *arXiv:2503.12907*, 2025.
- [30] Hong E, Park T, Kim Y. A survey on robust deep joint source-channel coding for semantic communications[R]. *arXiv:2604.04413*, 2026.
- [31] Ait Aoudia F, Hoydis J. End-to-end learning of communications systems without a channel model [C]//52nd Asilomar Conference on Signals, Systems, and Computers. 2018: 298-303.
- [32] Yellapragada S S, Kocharlakota A K, Costa M, et al. Computationally efficient neural receivers via axial self-attention[R]. *arXiv:2510.12941*, 2025.
- [33] Saleem O, Alfaqawi M, Merdrignac P, et al. Learning-based hybrid neural receiver for 6g-v2x communications[R]. *arXiv:2506.21983*, 2025.
- [34] Gallager R G. Low-density parity-check codes[J]. *IRE Transactions on Information Theory*, 1962, 8(1): 21-28.
- [35] MacKay D J C, Neal R M. Near shannon limit performance of low density parity check codes[J].

- Electronics Letters, 1997, 33(6): 457-458.
- [36] 3GPP. NR; physical channels and modulation: Ts 38.211[S]. 3rd Generation Partnership Project, 2024.
 - [37] 3GPP. NR; multiplexing and channel coding: Ts 38.212[S]. 3rd Generation Partnership Project, 2024.
 - [38] Proakis J G, Salehi M. Digital communications[M]. 5th ed. New York: McGraw-Hill, 2008.
 - [39] Weng Z, Qin Z. Semantic communication systems for speech transmission[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(8): 2434-2444.
 - [40] Kingma D P, Welling M. Auto-encoding variational bayes[C]//International Conference on Learning Representations. 2014.
 - [41] Ballé J, Minnen D, Singh S, et al. Variational image compression with a scale hyperprior[C]//International Conference on Learning Representations. 2018.
 - [42] Richardson T J, Shokrollahi M A, Urbanke R L. Design of capacity-approaching irregular low-density parity-check codes[J]. IEEE Transactions on Information Theory, 2001, 47(2): 619-637.
 - [43] Goldsmith A. Wireless communications[M]. Cambridge: Cambridge University Press, 2005.
 - [44] Chang R W. Synthesis of band-limited orthogonal signals for multichannel data transmission[J]. Bell System Technical Journal, 1966, 45(10): 1775-1796.
 - [45] Weinstein S B, Ebert P M. Data transmission by frequency-division multiplexing using the discrete fourier transform[J]. IEEE Transactions on Communication Technology, 1971, 19(5): 628-634.
 - [46] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: From error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

致谢

在大一时，就看到了许多感人良多的致谢，那时，还认为时间很长，甚至都没畅想过自己写致谢的情景，哪怕我是个喜欢畅想的人。当现在敲下这段话时，才真切的意识到我的大学要结束了。

能还算顺利的走到今天，当然也包括完成毕业论文，要感谢我的导师，吴铭老师在学习、科研、生活上都帮助了我很多，让我有了很大的收获，在本科期间能遇上吴铭老师，是很幸运的事。其他课程老师也真的非常非常好，在学业上给予了我很多帮助，感谢他们。

必须要感谢的就是一路走来相互陪伴的朋友，正是你们的存在，才让我的大学生活变得精彩与开心，靠近了高中时期脑海中滤镜中的生活。每当我遇到学业上的困难亦或是心情上的失落，你们是最坚实的后盾，能让烦恼随风。我想如果另一个平行世界的我没有你们，也许已经在某处倒下了。

谢谢我的辅导员，让我真切的体验到了师生之间的另一种相处方式。还要感谢帮助过我的学长学姐以及可能素未谋面的陌生人，你们让我感受到了人心的温暖，我也很好的传承了下去。

最后，一定要致谢的就是我的家人，是你们的托举，让我始终从未害怕过，因为我的身后有家。

经历塑造人生，感谢我的所有经历，不论是开心的亦或是难过的，已经走过，都让我成长，变得更强大。在这四年中，我明白了很多之前不懂的事与理，觉得自己又长大了一点，终于懂得以前大人所说的小孩多好，无忧无虑，只关心分数就可以。但既然时光不能倒流，我将一直往前走，追随心中所想。

其他人再好也与我无关，珍惜对我好，真诚待我的人，我真心的祝愿你们身体健康，开开心心。也在最后祝自己，没事笑一笑，有事更要笑，哈哈哈哈哈！